Eksamen I "Biostatistik og epidemiologi" på kandidatuddannelsen i medicin på Syddansk Universitet - November 2025

I har fået udleveret artiklen "Møller SE et al (2014) Risk of Childhood Overweight after Exposure to Tobacco Smoking in Prenatal and Early Postnatal Life" samt et simuleret datasæt i både R- og Stata-format ("Moeller.Rdata" og "Moeller.dta").

Epidemiologi

Opgave 1

A) Definér kort begreberne konfounder, effektmodifikator og mediator.

B) I artiklen angiver forfatterne, at amning potentielt kan være en mediator i sammenhængen mellem eksponering (rygning efter fødslen) og udfald (overvægt ved 7-års alder). Antag teoretisk, at amning faktisk er en mediator i sammenhængen. Forklar teoretisk, hvordan amning i så fald fungerer som en mediator, og hvad der ville ske, hvis man justerede for amning i analysen af denne sammenhæng i stedet.

C) I artiklens figur 3 fremgår det, at odds ratioen for overvægt ved 7-års alderen er 1.31 (95% konfidensinterval: 1.15-1.48) ved rygning under graviditeten sammenlignet med ikke-rygende mødre. Nedenfor er et tænkt eksempel, hvor denne analyse er stratificeret for BMI:

	BMI <25	BMI ≥25
	Odds ratio (95% konfidensinterval)	Odds ratio (95% konfidensinterval)
Rygning under graviditet	1.14 (1.04-1.25)	1.38 (1.26-1.52)

Beskriv hvad den stratificerede analyse indikerer, og hvordan du kan undersøge det nærmere.

Svar 1A

- *Mediator:* ligger på den kausale vej (eksponering → mediator → udfald).
- *Konfunder:* er associeret med både eksponering og udfald.
- *Effektmodifikator:* ændrer styrken eller retningen af eksponeringens effekt

Svar 1B

Hvis amning fungerer som en mediator, betyder det, at den ligger på den kausale vej mellem eksponeringen (tobaksrøg) og udfaldet (barnets overvægt som 7-årig). Det vil sige, at tobaksrøg påvirker sandsynligheden for amning, og at amning i sig selv påvirker risikoen for overvægt.

Hvis man i analysen (fejlagtigt) justerer for amning, fjerner man den del af sammenhængen, der går gennem amning – altså den indirekte effekt. Dermed vil man kun måle den direkte effekt af tobaksrøg på overvægt. Resultatet bliver derfor et svagere estimat (gå mod nul-hypotesen).

Svar 1C

De stratificerede analyser indikerer, at BMI kan være en effektmodifikator, da effekten af eksponering (rygning under graviditet) på udfaldet (overvægt ved 7-års alder) fremstår forskellig mellem de to subgrupper af BMI. Effekten af rygning under graviditet på odds for overvægt ved 7 år varierer med

moderens BMI. For at undersøge dette nærmere kunne vi indsætte et interaktionsled i analysen fra figur 3, og begge analyser kunne rapporteres.

Opgave 2 om informationsproblemer

A) Forklar de to former for misklassifikation med udgangspunkt i målingen af udfaldet i artiklen og hvordan de hver især ville påvirke estimatet. Hvilken form for misklassifikation, tænker du, der er?
B) Faderens rygestatus ser ud til at være målt binært. Eftersom variablen bruges som justeringsvariabel i analyserne har måden, den er målt på, betydning for fortolkningen af resultaterne. Hvordan kunne faderens rygestatus bliver målt mere nuanceret? Hvis faderens rygestatus er en stærk konfunder, hvilken betydning har det så, at det er målt ret groft og unuanceret?
C) Moderens rygstatus er målt to gange under graviditeten og en gang efter fødslen. Hvordan ville det mon have påvirket målet for moderens rygestatus før og efter fødslen, hvis mødrene i stedet for kun blev spurgt om rygestatus ved 7-års followup?
D) Svar 2A
E) Der findes overordnet to typer misklassifikation: non-differentieret og differentieret.
F) Non-differentieret misklassifikation af udfaldet betyder, at eventuelle målefejl i højde eller vægt ikke afhænger af eksponeringen (rygning under eller efter graviditeten). Denne type fejl vil typisk føre til bias mod nul, dvs. at man underestimere den sande sammenhæng mellem rygning og risiko for overvægt.
G) Differentieret misklassifikation af udfaldet betyder, at sandsynligheden for fejl i målingen afhænger af eksponeringen – fx hvis børn af rygere konsekvent blev målt anderledes end børn af ikke-rygere. Det virker dog usandsynligt, at rygning under graviditeten skulle påvirke præcisionen af højde- og vægtmålinger syv år senere.
H) Samlet vurderes der derfor ikke at være differentieret misklassifikation, og eventuel non-differentieret misklassifikation vil sandsynligvis være lille, da højde og vægt måles med standardiserede metoder og høj præcision.
I)
J) Svar 2B
K) Faderens rygestatus kunne være målt på samme måde som moderens rygestatus med både angivelse af hvor meget faderen røg og om det var før og/eller efter fødslen. Nyttig information kunne altså være rygestatus i forhold til fødsel (før og/eller efter) samt hvor meget faderen røg. Hvis der justeres for faderens rygning, og dette mål er ret groft og unuanceret, kan der være residual konfundering. Det betyder, at selvom vi justerer for faderens rygestatus, kan vi ikke fjerne hele effekten af konfunderen, da det er målt groft og unuanceret.
L)
M) Svar 2C
N) Måling af rygestatus ved 7-års followup øger risikoen for *recall bias*, da det er vanskeligt for deltagerne at huske rygningens omfang flere år tilbage. Hvis moderens rygestatus før og efter fødslen blev målt ved 7-års followup, vil der være stor sandsynlighed for recall bias. Det kan være svært at huske detaljer i år tilbage i forhold til rygning og antallet af cigaretter dagligt.

Opgave 3

A) Gør kort rede for studiepopulationen.
B) I det endelige studie deltog kun 61 % af dem, der indgik i dette studie (Møller et al., 2014). Forestil dig derudover, at selve deltagelsen i 7-årsopfølgningen afhænger af både moderens rygeadfærd og barnets vægtstatus. Hvordan kan en sådan selektion skabe en *differentieret selektionsbias* i undersøgelsen?
C) Hvad betyder en sådan differentieret selektionsbias for estimatet af sammenhængen mellem perinatal rygning og overvægt?

Svar 3A

Studiepopulationen tager udgangspunkt i The Danish National Birth Cohort (DNBC) og omfatter alle, som har besvaret 7-års opfølgningen (N = 53.888). Børnene skulle være levende, enkeltfødte børn i > 37 gestationsalder <43 med angivelse af fødselsvægt. Mødrene skulle have deltaget i alle tidligere interviews, og der skulle foreligge valide og samtidige højde- og vægtmålinger af barnet mellem 5 og 8½ års alderen. Børn af mødre med præeklampsi eller diabetes blev ekskluderet. Den endelige studiepopulation bestod af 32.747 mor-barn par.

Svar 3B

Hvis rygende mødre med overvægtige børn er mindre tilbøjelige til at deltage i 7-års opfølgningen end ikke-rygende mødre med normalvægtige børn, vil deltagelsen afhænge af både eksponering (rygning) og udfald (overvægt). Dette skaber *differentieret selektion*. Den endelige studiepopulation bliver dermed ikke repræsentativ for den oprindelige kohorte, og sammenhængen mellem perinatal rygning og overvægt kan blive forvrænget.

Svar 3C

En differentieret selektionsbias kan ændre estimatet i begge retninger. I dette tilfælde vil lav deltagelse blandt rygende mødre med overvægtige børn sandsynligvis føre til en *undervurdering* af den sande sammenhæng, da netop denne gruppe underrepræsenteres i data. Estimatet vil derfor sandsynligvis vise en svagere sammenhæng end den reelle.

Biostatistik

Opgave 4

Figur 3 i artiklen viser OR for forskellige sammenligninger mellem moderens rygning på forskellige tidspunkter (kun under graviditet, kun efter fødslen, eller begge perioder) og risikoen for overvægt hos barnet ved 7 år, samt forskellige modeller.

A) Hvorfor er ikke-rygerne ikke med i figuren?
B) Forklar hvordan 1.76 (1.58-1.97) for model 1, ved rygning i begge perioder, cirka midt på figuren skal fortolkes.
C) Figuren viser tre forskellige modeller, symboliseret ved hvert sit ikon. Er er mønsteret med at modellerne oppefra og ned bevæger sig mod højre forventeligt? Hvorfor/hvorfor ikke?

Svar 4A

Ikke-rygerne er ikke med i figuren, fordi det er referencegruppen, som per automatik har en OR=1.

Svar 4B

Det er OR fra modellen (model 1) justeret for mange kovariate, men ikke farens BMI og amning. Den fortolkes som at de børn, hvis mor røg i graviditeten og efter fødslen har 76% højere odds for overvægt sammenlignet med børn af en mor der ikke ryger. De 1.58-1.97 er konfidensintervallet og udtrykker at vi er 95% sikker på at den sande OR er mellem 58% og 97% forhøjet odds.

Svar 4C

Da modellerne er mere justeret jo længere op vi går, svarer det at OR kommer tættere på 1, når der justeres for mere. Dette er et udbredt fænomen, da justering ofte vil fjerne noget at den observerede sammenhæng, det er dog ikke noget der sker med sikkerhed, effekten kunne godt gå den anden vej.

Opgave 5

I har fået udleveret datasættet "Moeller.Rdata" hhv. "Moeller.dta", som minder om artiklens data (men som er simulerede data). Det indeholder følgende variabler:

- id: Et ID-nummer for hver person i datasættet
- overweight: Om barnet er overvægtigt ved 7-års alderen (0=nej, 1=ja)
- sex: Barnets køn (0=dreng, 1=pige)
- maternalage: Morens alder ved barnets fødsel (i år)

Besvar baseret på datasættet følgende spørgsmål:

A) Foretag en ujusteret logistisk regression med overvægt som udfald og køn som eksponering. Fortolk resultaterne.
B) Juster regressionen fra A) for morens alder. Fortolk resultaterne
C) Hvilke modelantagelser har modellen fra B)? Tjek relevante modelantagelser på data.

Svar 5A

```
load("Moeller.RData")

logreg <- glm(factor(overweight) ~ factor(sex), data = Moeller, family = "binomial")

summary(logreg)

exp(coef(logreg))

exp(confint(logreg))
```

Vi bestemmer en OR på 1.23 med et 95%-konfidensinterval på 1.14-1.33.

Så piger har 23% højere odds for overvægt end drenge, og vi~~u~~ er 95% sikker på at disse øgede odds er mellem 14% og 33% forøgelse.

Svar 5B

Justeret for morens alder er OR for køn stadig OR=1.23, så justeringen ændrer meget lidt. Vi kan også se at morens alder ikke er tydelig associeret med overvægt (P=0.051 og OR=0.991).

Svar 5C

Modelantagelserne er at observationerne er uafhængige, det kan vi ikke tjekke på datasættet, men virker rimeligt fra studiedesignet. Desuden at sammenhængen med morens alder er log-lineær og at modellen har god overensstemmelse med data. Disse to ting kan vi tjekke med Hosmer-Lemenov-testen, som giver en p-værdi på 0.316, hvilket peger på en acceptabel overensstemmelse.

Opgave 6

Brug samme datasæt som i opgave 5 og besvar følgende spørgsmål:

A) Lav koden for en prædiktionsmodel, der prædikterer risikoen for overvægt baseret på barnets køn og morens alder og forklar hvad i gør.
B) Tegn en ROC-kurve og beregn AUC for denne prædiktionsmodel A). Giv en vurdering af, om modellen er en Vurderer i at det er en god/ og velegnet prædiktionsmodel?
C) Overvej, på baggrund af artiklen, hvilke andre prædiktorer, vi burde tage med i en prædiktionsmodel, for at kunne opnå en bedre prædiktion.

Svar 6A

Vi anvender en logistisk regression til at prædikere overvægt baseret på køn og morens alder for alle børn i datasættet.

```
logreg <- glm(factor(overweight) ~ factor(sex)+maternalage, data = Moeller, family = "binomial")

Moeller = cbind(Moeller,response=predict(logreg, Moeller, type="response"))
```

Svar 6B

```
roc <- roc(Moeller$overweight,Moeller$response)

roc

plot(1-roc$specificities,roc$sensitivities,type="l")
```

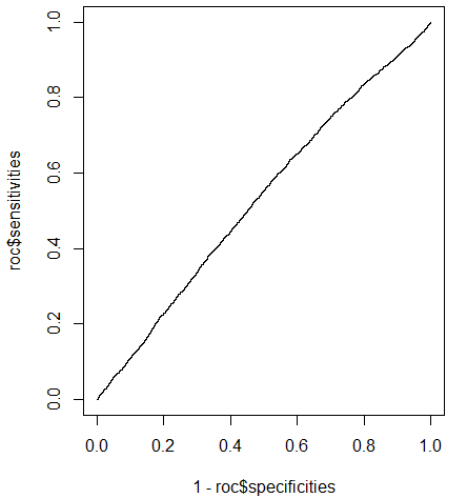

AUC er kun cirka 0.53, så prædiktionen er ret dårligt.

Svar 6C

Artiklen opdager at morens rygning har stor effekt på risikoen for overvægt, så denne skulle klart inkluderes. Desuden kan mange af de andre signifikante variable i Tabel 2 (fødselsvægt, ammetid, …) overvejes.