Epidemiologi

Selektionsproblemer

Mette Bliddal

Klinisk Institut, SDU

mbliddal@health.sdu.dk

Biostat-Epi, Medicin valgfag F2026

SDU

I dag

Læringsmål

At kunne identificere og diskutere selektionsbias og disses betydning for fortolkning af resultaterne i epidemiologiske studier

Herunder:

Forklarer hvordan selektionsbias påvirker beskrivende mål

Forklarer hvordan de påvirker associationsmål

Hvad er bias?

Bias = Systematisk skrævridning af resultater

Det kan være på grund af:

Uhensigtsmæssig udvælgelse af studiepopulationen

Uhensigtsmæssige/upræcise målemetoder

Validiteten af vores studie

Påvirker validiteten af vores estimater!

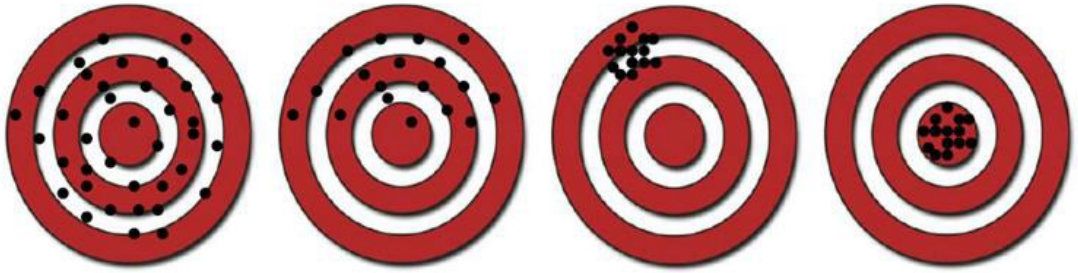

Ekstern validitet: Kan resultaterne generaliseres til en bredere befolkning?

Intern validitet: Troværdighed af vores resultat. Hvis et studie er validt, vil resultatet af studiet være korrekt.

Er den målte association et godt estimat for den kausale effekt?

Høj validitet = ingen systematiske fejl = ingen bias

Typer af bias

Selektionsbias

Informationsbias (misklassifikationsbias)

Immortal time bias

Reverse causation bias

(Confounding)

Hvordan ved vi, om der er systematiske fejl?

Det ved vi for det meste ikke!!

Derfor bliver vi nødt til at udlede det (Deducere).

Bias og confounding

Tilfældig variation

Systematisk variation (bias)

Selektionbias

Informationsbias

Confounding

Statistikerens ekspertise

Epidemiologens ekspertise

Selektionsbias

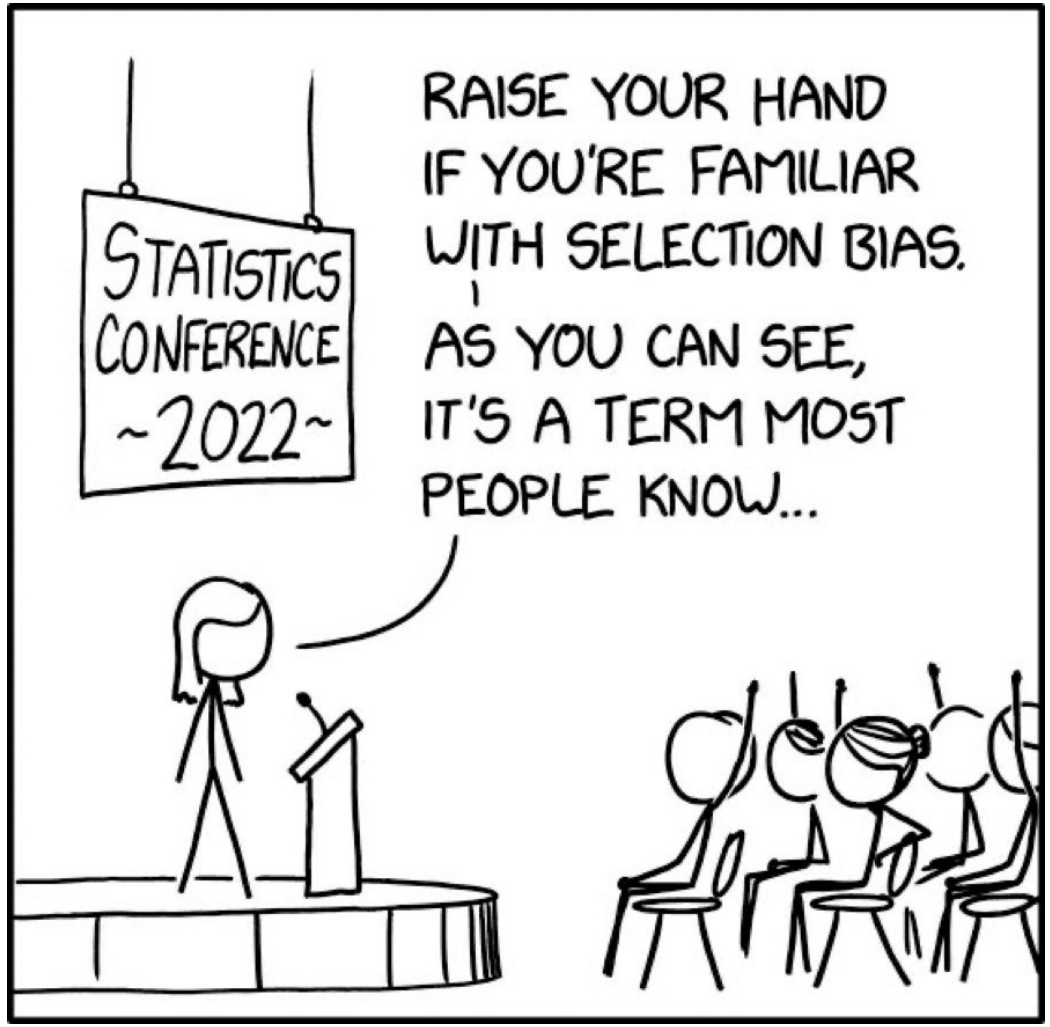

Randal Munroe, xkcd.com

Miniøvelse: Bias eller ej?

Arbejd 2 og 2:
Hvilket scenarie giver selektionsbias i associationsmålet?

A) Kun eksponerede deltager oftere
B) Kun syge deltager oftere
C) Eksponerede syge deltager oftere

Forklar hvorfor.

Hvad er selektionsbias?

Selektionsbias opstår, når den gruppe personer, der indgår i en undersøgelse, systematisk adskiller sig fra den målpopulation, man ønsker at udtale sig om.

Det betyder, at resultaterne kan blive skæve og ikke repræsentative, fordi udvælgelsen af deltagere ikke er tilfældig eller neutral.

Bias kommer udefra – selektiv inklusion af individer med særlige karakteristika – relateret til enten eksponering eller outcome.

Eksempler:

Kvinder med vage tegn på DVT vil oftere blive henvist til undersøgelse, hvis de bruge p-piller.

Mødre til børn med misdannelser vil være mere tilbøjelige til at deltage i en undersøgelse af medicinforbrug i graviditeten, hvis de selv mistænker et præparat, som de har taget, for at forårsage misdannelser.

Psykisk lidelse hos forældre i tidlig barndom (< skolestart)

→

Kognition ved session
(Børge Prien test ≈ IQ test)

Udfordringer:

1) Få kvinder, vi ender med kun at lave på mænd
2) Ikke alle unge mænd har været til session… hvem har ikke?

Hvem deltager i studiet?

Det er på ingen måde tilfældigt!

Mere privilegerede, bedre helbred eller udvalgt forkert af os.

Selektion – deskriptive mål

DANSKERNES SUNDHED

Tal fra Den Nationale Sundhedsprofil

2021: Udsendt 324.000 tilfældigt udvalgte danskere

Overordnet svarprocent: 57%

	2021	
	%	Antal inviterede
Mænd		
16-24 år	37,0	21.521
25-34 år	32,0	23.973
35-44 år	41,0	22.398
45-54 år	51,6	27.398
55-64 år	62,1	25.743
65-74 år	74,0	22.004
≥75 år	70,9	16.982
Alle mænd	52,0	160.019
Kvinder		
16-24 år	52,0	19.939
25-34 år	46,3	22.988
35-44 år	54,2	22.273
45-54 år	63,1	26.977
55-64 år	71,3	26.254
65-74 år	76,1	23.393
≥75 år	62,2	22.157
Alle kvinder	61,2	163.981
Civilstand		
Gift	65,5	149.531
Fraskilt	61,4	20.852
Enke/enkemand	58,2	37.618
Ugift	44,0	115.997

Miniøvelse: Hvad bliver påvirket?

Spørgsmål:

Andelen af rygere er højst blandt lavt uddannede. Lavt uddannende deltager sjældnere.

2 og 2:

Hvad bliver påvirket?

- Prævalence af rygning?
- Relativ risiko mellem rygning og sygdom?

Begrund kort

Eksempel

Bedre sundhed i generationer

78.000 kvinder (30% af gravide kvinder 1997-2002)

Fulgt op i 2013-14

Deltagelsesprocent: 53%

Naturlige spørgsmål:

Hvad betød ikke-deltagelse for de deskriptive mål?

Bliddal et al. American journal of Epidemiology, 2018

Table 1. Characteristics of the Baseline Cohort (1996–2002) and the Maternal Follow-up Subset (2013–2014) in the Danish National Birth Cohort

Variable	Baseline Cohort (n = 78,010) %[c]	Maternal Follow-up (n = 41,466) %[c]	Participation Rate, %	Prevalence Ratio[a]
Index-pregnancy prepregnancy BMI[e]				
<18.5 (underweight)	4.4	4.1	49.5	0.93
18.5–24.9 (normal-weight)	66.8	69.5	55.3	1.04
25.0–29.9 (overweight)	19.1	18.3	51.0	0.96
≥30.0 (obese)	8.0	6.6	43.8	0.82
Social status at baseline[f]				
Low	8.7	6.4	39.1	0.74
Middle	36.4	32.8	47.9	0.90
High	50.8	57.6	60.2	1.13
Smoking during index pregnancy				
Nonsmoking	73.2	77.9	56.5	1.06
Smoking cessation	9.7	9.3	50.7	0.95
Smoking	17.0	12.8	40.0	0.75

Overordnet deltagelses-grad 53,2%

SDU

Betyder det så noget?

På associationerne

Table 3. Odds Ratios and Adjusted Relative Odds Ratios Comparing Associations Between Risk Factors and Chronic Diseases in the Baseline Co
Danish National Birth Cohort, 1996–2014

Association	Crude OR				Adjusted[a] OR or ROR	
		Baseline Cohort		Maternal Follow-up			
		OR	95% CI	OR	95% CI	ROR	95% CI[b]
Prepregnancy BMI[d]–depression[e]							
<18.5 (underweight)		1.19		1.07		0.90	
18.5–24.9 (normal-weight)		1.00		1.00		1.00	
25.0–29.9 (overweight)		1.08		1.13		1.04	
≥30.0 (obese)		1.14		1.20		1.05	

Justeret for selektionsvariable

Selektionsbias

Mangel på repræsentation behøver ikke at være et problem

Hvornår giver selektion bias?

Når formålet er at rapportere absolutte tal (deskriptive tal), må selektionen ikke være associeret med den variable vi undersøger.

Når formålet er at afrapporterer sammenhænge (associationer), må selektionen ikke være afhængig af både eksponering og outcome. Det vil påvirke de interne sammenligner (validiteten).

Det kigger vi mere på nu….

Selektion - associationsmål

Der er en grad af selv-selektion.

Man er mere tilbøjelig til at deltage, hvis man selv er har en særlig interesse i eksponering eller udfald.

Så personer, der hverken har eksponering og/eller udfald, vil i mindre grad deltage i studiet (underrepræsentation)

Der findes differentieret og ikke-differentieret selektionsbias.

Selektionsbias opstår, først når selektionen er afhængig af eksponering **og** udfald (differentieret selektion).

Mere om det nu…

Selektionsbias: Tværsnitsundersøgelse

Tværsnitsundersøgelse af vegetarkost og hjertekarsygdomme (CVD)

Den sande sammenhæng:

	CVD	- CVD	I alt
Vegetar	10	100	110
Ikke-vegetar	30	300	330
I alt	40	400	440

OR = (10*300) / (100*30) = 1

Miniøvelse: Gæt retning

	CVD	- CVD	I alt
Vegetar	10	100	110
Ikke-vegetar	30	300	330
I alt	40	400	440

2 og 2:
Hvad hvis ikke-vegetarer deltager sjældnere.
Bliver OR så:

- For høj
- For lav
- Uændret

Hvorfor?

Selektionsbias: Tværsnitsundersøgelse

Tværsnitsundersøgelse af vegetarkost og hjertekarsygdomme (CVD)

Selektion: halvdelen af ikke-vegetarer deltager ikke. Fordeling **ikke** afhængig af udfald (CVD)

	CVD	- CVD	I alt
Vegetar	10	100	110
Ikke-vegetar	**15**	**150**	165
I alt	25	250	275

OR = (10*150) / (100*15) = 1

Ikke-differentieret selektion

Selektionsbias: Tværsnitsundersøgelse

Tværsnitsundersøgelse af vegetarkost og hjertekarsygdomme (CVD)

Selektion: Halvdelen af ikke-CVD'er svarer ikke. Fordeling ikke afhængig af eksponering (kost)

	CVD	- CVD	I alt
Vegetar	10	50	60
Ikke-vegetar	30	150	180
I alt	40	200	240

OR = (10*150) / (50*30) = 1

Ikke-differentieret selektion

Selektionsbias: Tværsnitsundersøgelse

Den sande sammenhæng:

	CVD	- CVD	I alt
Vegetar	10	100	110
Ikke-vegetar	30	300	330
I alt	40	400	440

OR = (10*300) / (100*30) = 1

Forstil jer nu, at der er mange ikke-vegetarer uden CVD som vælger ikke at deltage. Hvad betyder det for OR?

Lav deltagelse blandt dem, der ikke går op i vegetarkost og ikke har haft CVD

	CVD	- CVD	I alt
Vegetar	10	100	110
Ikke-vegetar	30	**150**	180
I alt	40	250	290

OR = (10***150**) / (100*30) = **0,5**

Det bliver (fejlagtigt) beskyttende at være vegetar

Differentieret selektion

SDU

Miniøvelse: Hvad blev selekteret væk?

Diskuterer 2 og 2:

Hvilken gruppe mangler der nu personer i?

	CVD	- CVD	I alt
Vegetar	10	100	110
Ikke-vegetar	30	150	180
I alt	40	250	290

- Eksponerede syge
- Eksponerede raske
- Ikke-eksponerede syge
- Ikke-eksponerede raske

Miniøvelse: Den generelle regel

Overvej jeres svar fra før.

Hvornår ændres et associationsmål?

a) Når selektion påvirker én variable?
b) Når selektion påvirker en bestemt kombination af eksponering og outcome

Hvordan genkender man selektionsbias?

Hvis selektion giver bias i OR eller RR, hvad vil man så typisk se?

	CVD	- CVD	I alt
Vegetar	10	100	110
Ikke-vegetar	30	150	180
I alt	40	250	290

- Alle celler ændres ens?
- Én bestemt kombination ændres mest?

Klinisk intuition: hvem mangler

I et studie af motion og hjertekarsygdomme.

Hvem deltager mindst?

- Syge og inaktive
- Raske og aktive
- Tilfældigt

- Hvad betyder det for retningen af bias?

Selektionsbias: case-kontrolstudie

KEY: At vælge den rigtige kontrolgruppe

Ønsker at undersøge sammenhængen mellem rygning og lungecancer

Kontroller: patienter på samme sygehus indlagt med andre sygdomme (hjertekar-, gastrointestinal- og lungesygdomme)

Rygning	Lungecancer -patienter	Andre patienter (kontrolgruppen)	Total
Ryger	647	621	1268
Ikke-ryger	2	28	30
I alt	649	649	1298

OR = (647*28)/(621*2) = **14,59**

Doll and Hill, BMJ 1950

Miniøvelse: Den rigtige kontrolgruppe

Hvilken kontrolgruppe er bedst?

A) Andre patienter med lungesygdomme
B) Baggrundsbefolkningen?

Hvad kan gå galt med A)?

Selektionsbias: case-kontrolstudie

Rygning	Lungecancer -patienter	Andre patienter (kontrolgruppen)	Total
Ryger	647	~~621~~ 521	1268
Ikke-ryger	2	~~28~~ 128	30
I alt	649	649	1298

~~OR = (647*28)/(621*2) = **14,59**~~

MEN er kontrolgruppen repræsentativ for baggrundsbefolkningen?

Nej, rygere er overrepræsenteret i kontrolgruppen, og det er 'sunde rygere' altså de har ikke lungecancer

OR = (647*128)/(521*2) = **79,5**

At finde den rigtige sammenligningsgruppe

Familie, naboer, patienter på sygehuset er ikke nødvendigvis repræsentative for den baggrundsbefolkning, som cases er udtrukket fra

Løsning kunne være: Nested case-kontrolstudie, hvor cases og kontroller trækkes fra samme kohorte. Her er de danske registre en guldgrube

Selektionsbias og studiedesign

Optræder i alle studiedesigns, men i højere grad i tværsnits- og case-kontrolstudier end i kohortestudier.

Når man laver kohortestudier, sker selektionen før udfaldet/outcome er kendt. Ingen sandsynlighed for at inklusion afhænger af outcome (men kan godt afhænge af eksponering).

Selektion i kohortestudie kan dog stadig forekomme, men man kan ofte justere sig ud af det. Man justerer for det, som der er selekteret på….

Miniøvelse: kohortelogik

Inklusion sker før vi kender outcomet.

2 og 2:

Hvorfor reducerer det risikoen for selektionsbias i associationsmål?

Deduktion

Created by Zky Icon
from Noun Project

- Overvej eksklusions- og inklusionskriterier
- Hvem er kontrolgruppen
- Er der loss-to-follow-up og af hvem?
- Er selektionen/loss-to-follow relateret til både eksponering og udfald?
- Overvej: Hvad er retningen og størrelsen på den potentielle bias?
- Det her er svært og vi kender sjældent svaret – tænk jer godt om

Hvordan minimere man risikoen for selektionsbias?

- I designprocessen
  - Stræb efter høj svarrate
  - Komplet follow-up (stræb efter høj svarrate i opfølgning)
  - Vælg den rette kontrolgruppe (i case-kontrolstudier)

- I analysefasen
  - Justering
  - Sensitivitetsanalyser
  - (imputation)
  - (vægtning)

Hvornår giver selektion bias i associationer?

Tænk på 2×2-tabellen:

Ikke-differentieret selektion

- Påvirkning af eksponering *eller* outcome
- interne sammenligninger bevares

Differentieret selektion

- afhænger af både eksponering og outcome
- én celle ændres mest
- associationen kan blive forkert

Spørg jer selv: "Hvem mangler i én bestemt kombination af eksponering og sygdom?"

Take home - Selektion

Deskriptive mål:

Er studiepopulationen repræsentativt? Ellers bias

Associationsmål:

Ikke-differentieret selektion = påvirker typisk ikke interne sammenligninger (ingen bias)

Selektion på eksponering er **ens** for syge og raske

Selektion på outcome er **ens** for eksponerende og ikke-eksponerede

Differentieret selektion = Bias kan gå i begge retninger

Selektion er **afhængig af både eksponering og outcome**, det vil sige at én celle i en 2*2 tabel skiller sig ud, f.eks. at det er de eksponerede syge, som deltager.

Opgaver

- I skulle gerne have læst artiklen ”Gallbladder Disease and Risk of Type 2 Diabetes in Postmenopausal Women: A Women's Health Initiative Study” af Aku et al. Opgaven tager udgangspunkt i artiklen.

Tak for i dag

Tak til de skuldre, jeg står på – og som jeg har ladet mig inspirere af eller lånt materiale fra: Amalie Timmermann, Anton Pottegård og Ellen Nøhr

SDU