Prædiktionsmodeller

Sören Möller

Institut for Sundhedstjenesteforskning
Syddansk Universitet

10. marts 2026

Forskellen mellem prædiktion og inferens

- Det vi indtil nu har beskæftiget os med i kurset er *inferens*:
  - Udtale os om egenskaber eller sammenhænge i den population, vores stikprøve er taget fra
- I dag snakker vi om *prædiktion*:
  - Fordsusige, hvad vi vil forvente af nye observationer fra populationen
- Prædiktion introducerer ekstra usikkerhed/variation, fordi den også skal tage højde for variationen mellem nye observationer
- Eksempler for prædiktion:
  - Hvad er den forventede vægt efter 10 dage for et barn født vejende 3000 g?
  - Hvad er en patients risiko for tilbagefald af tarmkræft indenfor 5 år?

Prædiktion på numerisk udfald

- For at prædiktere numerisk udfald bruger vi lineær regression
- Vi skal beslutte værdien for alle forklarende variable, for de (nye) individer vi ønsker at udttale os om
  - For eksempel: Vi ønsker at forudsige blodtryk, for en 70-årig mand, der vejer 100 kg og ryger
- Denne forudsigelse kan udstyres med to forskellige usikkerheds-intervaller:
  - Konfidensinterval: Vi er 95% sikker på at **gennemsnittet** af (mange) nye observationer med disse forklarende variable vil ligge i dette interval
  - Prædiktionsinterval: 95% af **alle** nye observationer med disse forklarende variable vil ligge i dette interval
- Prædiktionsintervaller er typisk meget bredere end konfidensintervaller

Prædiktion på numerisk udfald i R

```
> linreg <- lm(BMI ~ Weight+factor(Gender), data=bmi)
> new_bmi <- data.frame(Weight=c(80,75),Gender=c("Male","Female"))
> new_bmi
  Weight Gender
1     80   Male
2     75 Female
> cbind(new_bmi,predict(linreg, newdata = new_bmi, interval = "confidence"))
  Weight Gender      fit      lwr      upr
1     80   Male 28.76821 27.63254 29.90387
2     75 Female 26.44749 25.27893 27.61605
> cbind(new_bmi,predict(linreg, newdata = new_bmi, interval = "predict"))
  Weight Gender      fit      lwr      upr
1     80   Male 28.76821 13.27925 44.25716
2     75 Female 26.44749 10.95609 41.93889
```

At evaluere prædiktion på numeriske udfald

- Typisk evaluerer vi prædiktion, ved at
  - køre modellen på en (tilfældig) del af datasættet (ofte 70%) (*training*)
  - prædiktere resultater på resten af datasættet (ofte 30%) (*validation*)
  - vurdere hvor godt vi ramte resultatet
- En måde at vurdere det på for numeriske udfald er at tegne de sande værdier mod prædiktionen
  - Det kan gøres på både training og validation data
  - Men validation er klart vigtigst
  - Det kan eventuel suppleres med en korrelation

At evaluere prædiktion på numeriske udfald i R

```
> set.seed(42)
> bmi$training = rbinom(dim(bmi)[1],1,0.7)
> head(bmi)
# A tibble: 6 × 6
  Gender Height Weight Index   BMI training
  <chr>   <dbl>  <dbl> <dbl> <dbl>    <int>
1 Male      174     96     4  31.7        0
2 Male      189     87     2  24.4        0
3 Female    185    110     4  32.1        1
4 Female    195    104     3  27.4        0
5 Male      149     61     3  27.5        1
6 Male      189    104     3  29.1        1
> linreg <- lm(BMI ~ Weight+factor(Gender), data=subset(bmi,training==1))
> bmi2 = cbind(bmi,predict(linreg, newdata = bmi, interval = "predict"))
> head(bmi2)
  Gender Height Weight Index      BMI training      fit       lwr      upr
1   Male    174     96     4 31.70828        0 35.26839 19.369775 51.16701
2   Male    189     87     2 24.35542        0 32.00351 16.098508 47.90851
3 Female    185    110     4 32.14025        1 38.99799 23.103598 54.89237
4 Female    195    104     3 27.35043        0 36.82140 20.927829 52.71497
5   Male    149     61     3 27.47624        1 22.57163  6.628335 38.51493
6   Male    189    104     3 29.11453        1 38.17051 22.274594 54.06642
```

Figur: Trainingsdata

```
> plot(subset(bmi2,training==1)$BMI,subset(bmi2,training==1)$fit)
> abline(0,1)
> cor(subset(bmi2,training==1)$BMI,subset(bmi2,training==1)$fit)
[1] 0.8246979
```

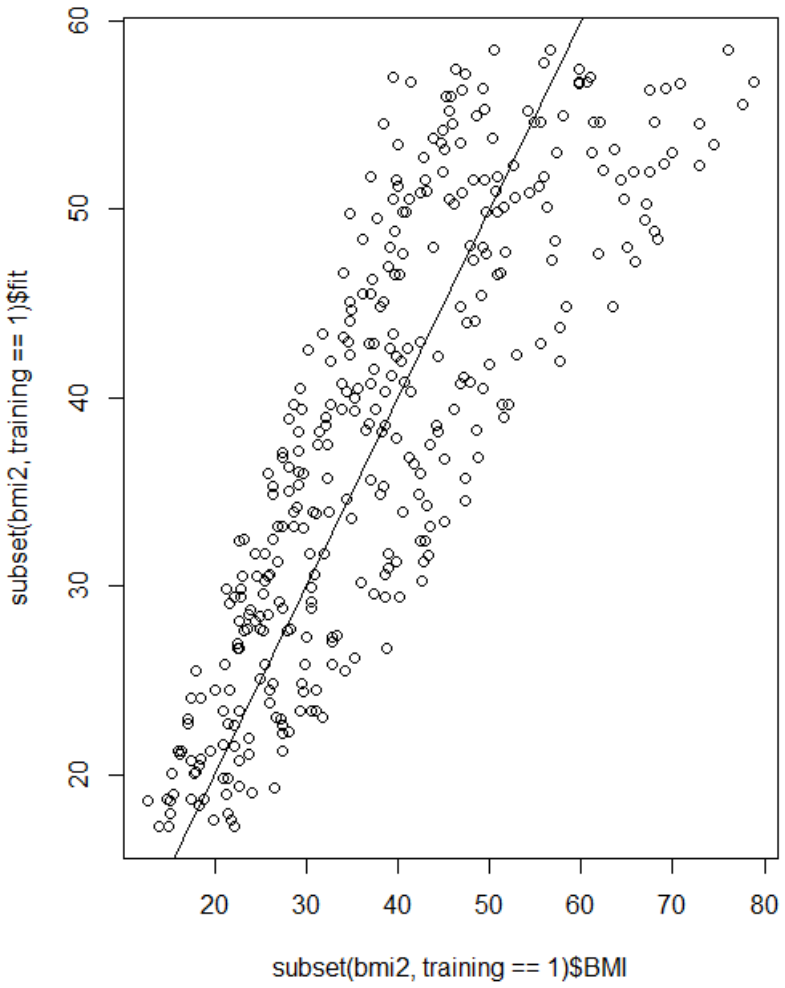

Figur: Valideringsdata

```
> plot(subset(bmi2,training==0)$BMI,subset(bmi2,training==0)$fit)
> abline(0,1)
> cor(subset(bmi2,training==0)$BMI,subset(bmi2,training==0)$fit)
[1] 0.8377498
```

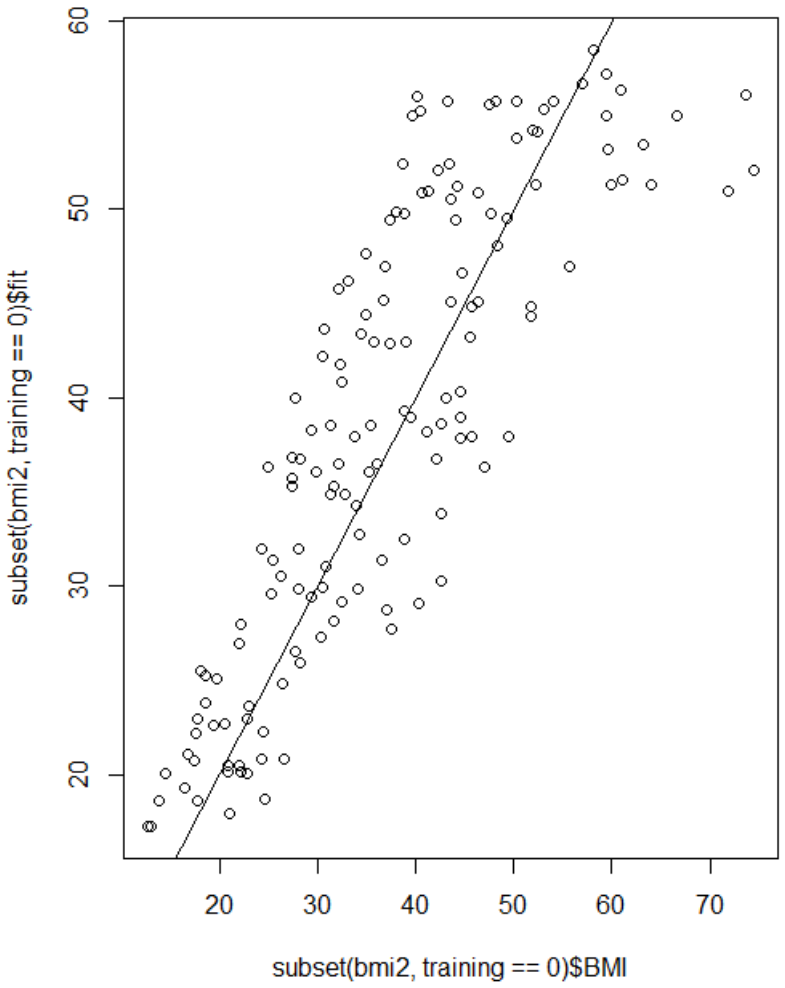

Opmærksomhedspunkter: Prædiktion på numeriske udfald

- Prædiktion på lineær regression er meget mere følsom ift. modelantagelser end inferensen
  - Normalfordelte residualer er forudsætningen for prædiktionsintervaller
  - Varianshomogenitet er nødvendigt for at prædiktionsintervaller har den rigtige bredte for alle værdier
  - Prædiktionen bruger lineariteten meget eksplicit
- Derfor bør man:
  - Tjek modelantagelserne for regressionen
  - Tjek om prædiktionen virker på træningsdata
    - Kan modellen beskrive de oprindelige data?
  - Tjek om prædiktionen virker på valideringsdata
    - Kan modellen beskrive nye data?
- Vær opmærksom på bredten på prædiktionsintervaller, hvis prædiktionen skal bruges på enkeltpersoner

Sammenfatning: Prædiktion på numeriske udfald

- Kan let gennemføres med en lineær regression
- Kræver kendskab til alle forklarende variable for dem vi ønsker at prædiktere på
  - Dette kan være begrundelsen for at udelade variable, der ikke ville være tilgængelig i klinisk praksis
- Vurder modellen
  - Statistisk: Er modelantagelserne opfyldt?
  - Epidemiologisk: Virker modellen (næsten) lige så godt på valdieringsdata som på træningsdata? (generaliserbarhed)
  - Klinisk: Er prædiktionsintervallerne smalle nok, til at prædiktionen er brugbar i praksis?

Prædiktion på dikotome udfald

- For at prædiktere dikotome udfald bruger vi logistisk regression
  - Kunne også gøres med log-binomial regression, men gøres sjældent
- Vi skal beslutte værdien for alle forklarende variable, for de (nye) individer vi ønsker at udttale os om
  - For eksempel: Vi ønsker risikoen for genindlæggelse indenfor 30 dage, for en 80-årig kvinde med diabetes, der har fået en ny hofte
- Prædiktionen giver os for hver ny person sandsynligheden for udfaldet (mellem 0 og 1)
- Prædiktionsinterval bruges ikke i denne sammenhæng
  - Fordi resultatet i forvejen er en sandsynlighed, og sandsynlighed for en sandsynlighed er forvirrende

Prædiktion på dikotome udfald i R

```
> logreg <- glm(factor(Outcome) ~ Glucose+BMI, data = diabetes,
family = "binomial")

> diabetes_new <- data.frame(BMI=c(20,28),Glucose=c(90, 170))
> diabetes_new
  BMI Glucose
1  20      90
2  28     170

> cbind(diabetes_new,response=predict(logreg, diabetes_new, type="response"))
  BMI Glucose   response
1  20      90 0.05605423
2  28     170 0.64575714
```

Bestemmelse af cut-off

- Typisk beslutter vi os for et cut-off for den forudsagte sandsynlighed
  - Dem der forudsiges over er i *høj risiko*
  - Dem der forudsiges under er i *lav risiko*
- Baseret på cutoff kan vi bestemme
  - TP: Sand positive (over cutoff og har udfaldet)
  - TN: Sand negativ (under cutoff og har ikke udfaldet)
  - FP: Falsk positive (over cutoff, men har ikke udfaldet)
  - FN: Falsk negativ (under cutoff, men har udfaldet)
- Cut-off bør vælges baseret på kliniske overvejelser
- Men der findes metoder, der kan foreslå et cut-off

Cut-off i R

```
> diabetes2 = cbind(diabetes,response=predict(logreg, diabetes, type="response"
> cutoff = 0.20
> diabetes2$highrisk = ifelse(diabetes2$response>=cutoff,1,0)
> head(diabetes2[,c("Glucose","BMI","Outcome","response","highrisk")])
  Glucose  BMI Outcome   response highrisk
1     148 33.6       1 0.56320879        1
2      85 26.6       0 0.07615396        0
3     183 23.3       1 0.66793644        1
4      89 28.1       0 0.09616240        0
5     137 43.1       1 0.64394113        1
6     116 25.6       0 0.18514289        0
> table(diabetes2$Outcome,diabetes2$highrisk)

     0   1
  0 255 245
  1  30 238
```

Sensitivitet / specificitet / PPV / NPV

- Ud fra forudsigelser med cut-off og det sande udfald can vi bestemme
- Sensitivitet: Hvor mange af de sand positive opdager vores prædiktion?

$$TP/(TP + FN)$$

- Specificitet: Hvor mange af de sand negative opdager vores prædiktion?

$$TN/(TN + FP)$$

- PPV/Positiv prædiktiv værdi: Hvis en prædiktion er positiv, hvad er sandsynligheden for at det er korrekt?

$$TP/(TP + FP)$$

- NPV/Negativ prædiktiv værdi: Hvis en prædiktion er negativ, hvad er sandsynligheden for at det er korrekt?

$$TN/(TN + FN)$$

Sensitivitet / specificitet / PPV / NPV i R

```
> #install.packages("caret")
> library(caret)
> sensitivity(factor(diabetes2$highrisk), factor(diabetes2$Outcome))
[1] 0.51
> specificity(factor(diabetes2$highrisk), factor(diabetes2$Outcome))
[1] 0.8880597
> posPredValue(factor(diabetes2$highrisk), factor(diabetes2$Outcome))
[1] 0.8947368
> negPredValue(factor(diabetes2$highrisk), factor(diabetes2$Outcome))
[1] 0.4927536
```

ROC-kurver og AUC

- For at evaluere en prædiktionsmodel for dikotomt udfald tegner vi typisk en ROC-curve
  - ROC = Reciever Operating Curve (mangler et godt dansk navn, plejer at sige ROC)
- Denne tegner sensitivitet (y-akse) mod specificitet (x-aksen, typisk inverteret)
- For alle mulige cut-offs mellem 0 og 1
- Går fra nederste venstre hjørne til øverste højre hjørne
- Jo længere mod øverste venstre hjørne kurven går, jo bedre
- Diagonalen svarer til at gætte (baseret på prævalens af udfald) AUC = Arealet under kurven (mellem 0 og 1) bruges til at kvantificere

Figur: ROC-kurve

```
> library(pROC)
> roc <- roc(diabetes2$Outcome,diabetes2$response)
Setting levels: control = 0, case = 1
Setting direction: controls < cases
> roc
Call:
roc.default(response = diabetes2$Outcome, predictor = diabetes2$response)
Data: diabetes2$response in 500 controls (diabetes2$Outcome 0) < 268 cases (diabetes2$Outcome 1).
Area under the curve: 0.8109
> plot(1-roc$specificities,roc$sensitivities,type="l")
```

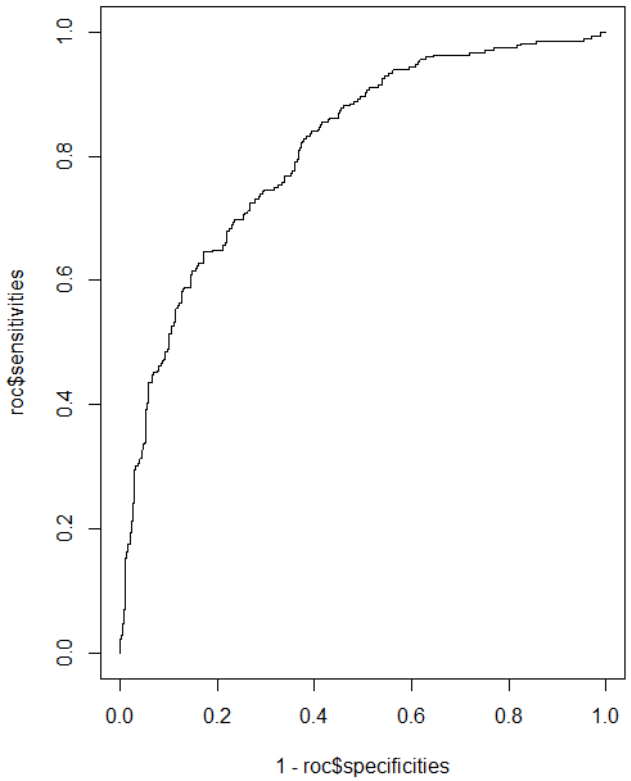

Opmærksomhedspunkter: Prædiktion på dikotome udfald

- Hvor godt modellen prædikterer afhænger meget af cut-off
- Cut-off skal vælges med hensyn til formålet med modellen
  - Balancerer sensitivitet og specificitet
  - Balancen er meget afhængigt af det kliniske formål
- Evaluer modellen med AUC
  - Overvej cut-off separat fra AUC, en god AUC med et dårlig cut-off virker ikke
  - AUC måler ikke kalibrering (alle prædiktioner kunne være for høje/lave)
  - Opdelt datasæt (som med lineær regression) kan anbefales
- Sensitivitet/specificitet er ikkeafhængige af prævalensen af udfaldet
- PPV/NPV er afhængige af prævalensen af udfaldet

Sammenfatning: Prædiktion på dikotome udfald

- Prædiktionen baseret på logistisk regression
- Kræver kendskab til alle forklarende variable for dem vi ønsker at prædiktere på
  - Dette kan være begrundelsen for at udelade variable, der ikke ville være tilgængelig i klinisk praksis
- Vurder modellen
  - Statistisk: Virker den logistiske regression og er AUC acceptabel?
  - Epidemiologisk: Er modellen kalibreret passende? Virker den på valideringsdata?
  - Klinisk: Er cut-off brugbar til formålet? Passer balancen mellem sensitivitet og specificitet

Spørgsmål?