Hypotesetests og konfidensintervaller

Sören Möller

Institut for Sundhedstjenesteforskning
Syddansk Universitet

10. februar 2026

Konfidensintervaller

- Sidste gang:
  - Vi beregnede konfidensinterval for en middelværdi
  - Vi beregnede konfidensinterval for en proportion
- Dette kan genrelt gøres for (næsten) alle ting vi estimerer i statistik
  - Middelværdier, proportioner (gøres ofte)
  - Medianer, kvartiler, spredninger, varianser (gøres sjældent)
  - Regressionskoefficienter, OR, RR, HR, ... (gøres ofte)
- Ideen er altid den samme
  - Bestem hvor sikkert vi vil være (typisk 95%)
  - Beregn et interval omkring estimatet som den ægte værdi ligger i med 95% sikkerhed
  - Vi foretrækker *med* 95% *sikkerhed* fremfor *med* 95% *sandsynlighed*, da den ægte værdi i hvert enkelt studie jo enten ligger eller ikke ligger i intervallet

Fortolkning af konfidensinterval (næsten gentagelse fra sidst)

Foretager vi 100 studier på tilsvarende datasæt fra den samme population og beregner et estimat forventer vi at (cirka) 95 af konfidensintervallerne indeholder den sande værdi.

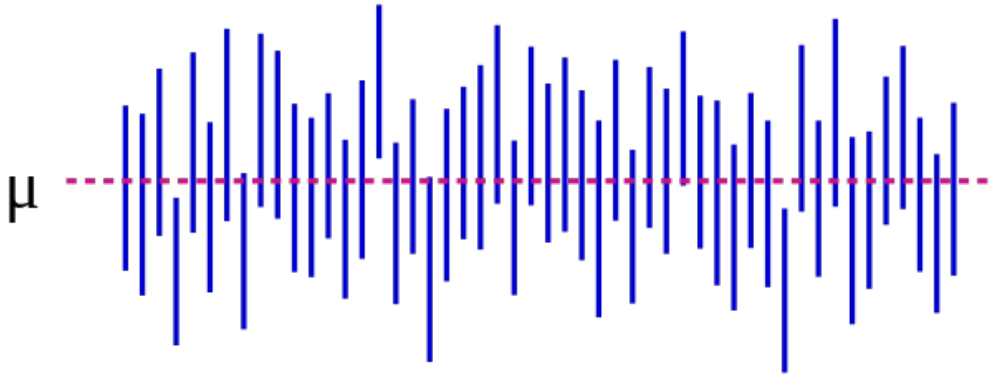

Vi siger at den sande værdi med **95% sikkerhed** ligger i konfidensintervallet og kalder det også for **sikkerhedsinterval**.

"Picturing 50 realisations of a 95%-confidence interval" by Tsyplakov - Own work. public domain via Wikimedia Commons

Hvordan beregner vi konfidensintervaller?

- I simple tilfælde findes der formlet (men vi bruger typisk en computer alligevel)
  - Middelværdier
  - Forskel mellem middelværdier
  - Proportioner
  - OR, RR (ujusteret)
- I mange tilfælde har computeren (f.eks. i R) en algoritme
  - Regressionskoefficienter
  - OR, RR (justeret)
  - HR, incidencer
- Hvis det heller ikke er tilgængeligt, kan der bruges approksimative metoder
  - Delta-metoden (bruges sjældent manuelt, men kan være implemenetret i software for specifikke tilfælde)
  - Bootstrapping
- På denne måde kan vi få konfidensintervaller til næsten alt vi ønsker

Konfidensinterval

```
> t.test(subset(runningtimes,Sex==0)$time2015)

        One Sample t-test

data:  subset(runningtimes, Sex == 0)$time2015
t = 245.59, df = 999, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 6.802726 6.912312
sample estimates:
mean of x
 6.857519
```

Lad os afprøve om konfidensintervallet virker (vis i R)

```
> res <- data.frame(estimat=c(), nede=c(),oppe=c())
> N <- 100
> set.seed(24)
> for (i in 1:10000){
+   x = rnorm(N,10,1)
+   ttest = t.test(x~1)
+   res = rbind(res,data.frame(estimat=ttest$estimate,
+                              nede=ttest$conf.int[1],
+                              oppe=ttest$conf.int[2]))
+ }
> count(10>=res$nede & 10<=res$oppe)
n_TRUE
  9495
> #Dette vil altid være opfyldt:
> count(res$estimat>=res$nede & res$estimat<=res$oppe)
n_TRUE
 10000
```

Konfidensinterval for proportion (vis i R)

```
> #install.packages("PropCIs")
> library(PropCIs)
> exactci(length(subset(coffee,coffee==1)$coffee),length(coffee$coffee)
+         ,conf.level=0.95)
95 percent confidence interval:
 0.2524008 0.3941547
> scoreci(length(subset(coffee,coffee==1)$coffee),length(coffee$coffee)
+         ,conf.level=0.95)
95 percent confidence interval:
 0.2561 0.3919
> #install.packages("fastR2")
> library(fastR2)
> wald.ci(length(subset(coffee,coffee==1)$coffee),length(coffee$coffee)
+         ,conf.level=0.95)
[1] 0.2516841 0.3887654
attr(,"conf.level")
[1] 0.95
> wilson.ci(length(subset(coffee,coffee==1)$coffee),length(coffee$coffee)
+           ,conf.level=0.95)
[1] 0.2561742 0.3921775
attr(,"conf.level")
[1] 0.95
```

Konfidensintervaller bliver smallere, jo flere data vi har

Tommelfingerregel: Intervallet er halvt så langt, hvis vi har fire gange så mange observationer

```
> set.seed(24)
> x = rnorm(100,10,1)
> ttest = t.test(x~1)
> ttest
95 percent confidence interval:
  9.688022 10.064314
> ttest$conf.int[2]-ttest$conf.int[1]
[1] 0.3762922
> x = rnorm(400,10,1)
> ttest = t.test(x~1)
> ttest
95 percent confidence interval:
  9.861595 10.064134
> ttest$conf.int[2]-ttest$conf.int[1]
[1] 0.2025393
> x = rnorm(1600,10,1)
> ttest = t.test(x~1)
> ttest
95 percent confidence interval:
  9.925178 10.024105
> ttest$conf.int[2]-ttest$conf.int[1]
[1] 0.09892758
```

Bootstrap

- Hvis ikke vi har en specifik måde til at beregne et konfidensinterval kan vi bruge bootstrap
  - Udtrækker tilfældigt (med tilbagelægning) data fra datasættet
  - Samme antal som det oprindelige datasæt
  - Beregner estimatet på disse datasæt
  - Der skal gerne være mange (mindst 1000) datasæt
  - På baggrund af dette kan der bestemmes et konfidensinterval
  - Metoden virker dårligt ved
    - Meget små datasæt (< 20)
    - Ved komplicerede modeller (f.eks. store regressionsmodeller)
  - Typisk lidt mindre præcis end de specifikke metoder

Bootstrap (vis i R)

```
> #install.packages("boot")
> library(boot)
> funk <- function(data, indices)
+ {
+   d <- data[indices]
+   return(mean(d))
+ }
> load(file="runningtimes.RData")
> results <- boot(data=subset(runningtimes,Sex==0)$time2015,
+                 statistic=funk, R=1000)
> boot.ci(results, type="bca")
BOOTSTRAP CONFIDENCE INTERVAL CALCULATIONS
Based on 1000 bootstrap replicates
CALL :
boot.ci(boot.out = results, type = "bca")
Intervals :
Level       BCa
95%   ( 6.800,  6.908 )
Calculations and Intervals on Original Scale
```

Hypotesetest (næsten gentagelse)

Ofte vil vi sammenligne vores estimat med en forud kendt værdi for at finde ud af, om der er en (signifikant) forskel.

H_0 :	observation	$=$	foventede		Nul-hypotese
H_a :	observation	$\neq$	foventede		Alternativ hypotese (tosidet)

- **p-værdien** er sandsynligheden for at få vores *estimat* eller noget der er længere væk fra det forventede, under antagelse af nulhypotesen er rigtigt.
- Etsidet: Vi kan også undersøge H_a med $<$ eller $>$ i stedet for $\neq$, så er det kun *længere væk* i en bestemt retning
- I nogle situationer kan man have mere komplicerede alternative hypoteser, men det sker sjældent

Eksempel: Hypotesetest for én middelværdi fra en normalfordeling

```
> t.test(subset(runningtimes,Sex==0)$time2015,mu=7)

        One Sample t-test

data:  subset(runningtimes, Sex == 0)$time2015
t = -5.1028, df = 999, p-value = 4.005e-07
alternative hypothesis: true mean is not equal to 7
95 percent confidence interval:
 6.802726 6.912312
sample estimates:
mean of x
 6.857519
```

Antager at observationerne er normalfordelt.

Eksempel: Hypotesetest for forskel mellem to middelværdier

```
> t.test(runningtimes$time2015~runningtimes$Sex)

        Welch Two Sample t-test

data:  runningtimes$time2015 by runningtimes$Sex
t = -18.107, df = 1995.5, p-value < 2.2e-16
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -0.7786639 -0.6264727
sample estimates:
mean in group 0 mean in group 1
       6.857519        7.560087
```

Antager at observationerne i begge grupper er normalfordelt.

Hypotesetests

- Hvis nulhypotesen er opfyldt og vi gentager studiet 100 gange forventes
  - (Cirka) 5 gange signifikant p-værdi (på 5% niveau)
  - (Cirka) 95 gange ikke-signifikant p-værdi (på 5% niveau)
- Hvis nulhypotesen ikke er opfyldt forventer vi signifikant p-værdi hyppigere end 5%
- Denne hyppighed kalder vi testens **styrke** (power). Den afhænger af:
  - Forskellen mellem 0-hypotese og virkelighed
  - Størrelsen på datasættet
  - Fordelingsegenskaber (f.eks. spredning)
  - Hvilken test vi bruger
- Med passende antagelser kan der på forhånd foretages en styrkeberegning, som kan hjælpe med at beslutte størrelsen på et studie

Styrkeberegning (vis i R)

```
> #install.packages("pwrss")
> library(pwrss)
> pwrss.t.2means(mu1 = 30, mu2 = 28, sd1 = 12, sd2 = 8, kappa = 1,
+                power=0.90, alpha = 0.05,
+                alternative = "not equal")
 Difference between Two means
 (Independent Samples t Test)
 H0: mu1 = mu2
 HA: mu1 != mu2
 ------------------------------
  Statistical power = 0.9
  n1 = 548
  n2 = 548
 ------------------------------
 Alternative = ‘‘not equal’’
 Degrees of freedom = 1094
 Non-centrality parameter = 3.246
 Type I error rate = 0.05
 Type II error rate = 0.1
```

Hvordan kan det være beskrevet i protokollen?

Sample size and power

With an expected peritonitis-related complications rate of 40% in the ROD group [20] and 25% in the VAC group [42, 44], the desired power of 80%, a significance level of 0.05, and an expected drop-out of 5%, a total of 340 patients should be included.

Patient characteristics will be summarised with frequencies and proportions (for categorical variables) or with mean values ± standard deviation, median values, quartiles, and minimum and maximum values (for numerical variables). Categorical variables will be compared using a Fisher's exact test and continuous variables with a Wilcoxon rank-sum test.
The primary peritonitis-related complication outcome will be compared between intervention groups by the Chi-square test, reported as relative risk with a 95% CI. The CCI outcome will be compared by linear regression with bootstrapped standard errors reporting the mean difference with 95% confidence intervals.

Figure: Rajabaleyan et al. 2020

Hypotesetests eller konfidensintervaller?

- Gennem de sidste år har der været en del diskussion i litteraturen om brug af tests/p-værdier eller konfidensintervaller
  - Greenland et al. 2016, *Statistical tests, P values, confidence intervals, and power: a guide to misinterpretations*
  - Wasserstein & Lazar 2016, *The ASA Statement on p-Values: Context, Process, and Purpose*
  - Og dens referencer og bilag, diskussionen er ikke ny
- Nogle (enkelte) tidsskrifter kræver at man kun rapporterer konfidensintervallet
- Mange opfordrer til at man også rapporterer konfidensintervaller (og estimater)
- Der er lidt variation mellem sundhedsvidenskabelige områder
- Tommelfingerregel: Rapporter begge ting, hvis ikke der er et klart argument for noget andet

Sammenhæng mellem hypotesetests og konfidensintervaller

- Hvis værdien for nulhypotesen ligger i (95%) konfidensintervallet, så er en to-sidet test ikke signifikant (på 5% signifikantsniveau)
- Hvis værdien for nulhypotesen ligger udenfor (95%) konfidensintervallet, så er en to-sidet test signifikant (på 5% signifikantsniveau)
- For sammenligning mellem to estimater med konfidensintervaller, er der nogle tommefingerregler:
  - Hvis de to konfidensintervaller ikke overlapper, så er de to estimater signifikant forskellig (i alle praktisk relevante situationer)
  - Det omvendte udsagn holder ikke: Konfidensintervaller kan sagtens overlappe og der samtidigt være signifikant forskel, når man tester
- Desuden kræver det at test og konfidensinterval bruger samme metode / model.

Spørgsmål?