Overlevelsesanalyse

Sören Möller

Institut for Sundhedstjenesteforskning
Syddansk Universitet

26. februar 2026

Overlevelsesdata

Overlevelsesdata handler om situationer hvor vi følger individer fra et starttidspunkt (fødsel, behandling, ...) og venter på om noget sker, vi observerer:

- Hvornår det skete (efter start)
- Hvornår vi stoppede observationen uden det skete (censorering)

Hvis ikke vi observerer alle individer i lige lang tid, kræver dette specialiserede metoder:

- Kaplan-Meier: ved gruppeinddeling
- Cox-regression: ved numeriske/flere kovariate

Hvis der er andre hændelser (død) der fjerne individer fra risikoen, skal der bruges udvidelser af disse metoder.

Antagelser

- Hændelsen sker kun én gang
  - Død
  - *Første* kræftdiagnose
- Hændelsen er irreversibel
  - Død
  - Vi tager ikke højde for helbredelse
- Alle individer starter i samme status
  - I live
  - Rask
- Ikke et krav at hændelsen sker for alle individer

Censorering

- Det primære analystiske problem i overlevelsesanalyse
- Vi kender ikke de præcise overlevelsestider for alle individer
- Årsager:
  - **Undersøgelsen slutter** før personen har hændelsen
  - Person **falder fra** i løbet af undersøgelsen
    - Patienten stopper med at deltage i undersøgelsen
    - Emigration
    - **Ikke umiddelbart:** Død (konkurrende risici)
- **Partiel information**: Personen havde ikke hændelsen før et kendt tidspunkt

Eksempel

Motions sammenhæng med efterfølgende skilsmisse for kvinder

- Eksponering: Motion (timer per uge) f.eks. fem år efter bryllup
- Udfald: Skilsmisse i de efterfølgende år
- Censorering: Nogle af kvinderne er stadig gift, men vil muligvis skilles i fremtiden
- Konkurrerende risici: Kvinder der dør bliver ikke skilt (kun et problem for gamle)
- Vi kunne bruge Cox-regression (hvis vi ser bort fra konkurrerende risici)
- Ignoreres censorering kunne vi overse mange tilfælde, måske systematisk

Eksempel i R

```
> load(file="drugtr.RData")
> head(drugtr)
# A tibble: 6 × 4
  studytime  died  drug   age
      <dbl> <dbl> <dbl> <dbl>
1         1     1     0    61
2         1     1     0    65
3         2     1     0    59
4         3     1     0    52
5         4     1     0    56
6         4     1     0    67
>
```

- studytime: Tid patienten er fulgt (i måneder)
- died: Om patienten døde (=1) eller er censureret (=0)
- drug: Om patienten fik den nye (=1) eller gamle (=0) behandling
- age: Patientens alder

Kaplan-Meier-metoden

- Kaplan-Meier-metoden beregner, hvor mange der har udfaldet inden en given tid
- Hvor der tages højde for censurering, så antal personer i risiko er korrekt

$$\widehat{S}(t) = \prod_{i:\ t_i \leq t} \left(1 - \frac{d_i}{n_i}\right)$$

- Her er
  - t_i de forskellig tidspunkter i datasættet hvor udfald/censorering sker
  - d_i antal udfald til tid t_i
  - n_i antal personer stadig i risiko (dvs. hverken udfald eller censorering) til tid t_i

Figur: Kaplan-Meier

```
> library(survival)
> km <- survfit(Surv(studytime, died) ~ 1, data=drugtr)
> km
Call: survfit(formula = Surv(studytime, died) ~ 1, data = drugtr)

      n events median 0.95LCL 0.95UCL
[1,] 48     31     17      12      25
> #install.packages("ggfortify")
> library(ggfortify)
> autoplot(km)
```

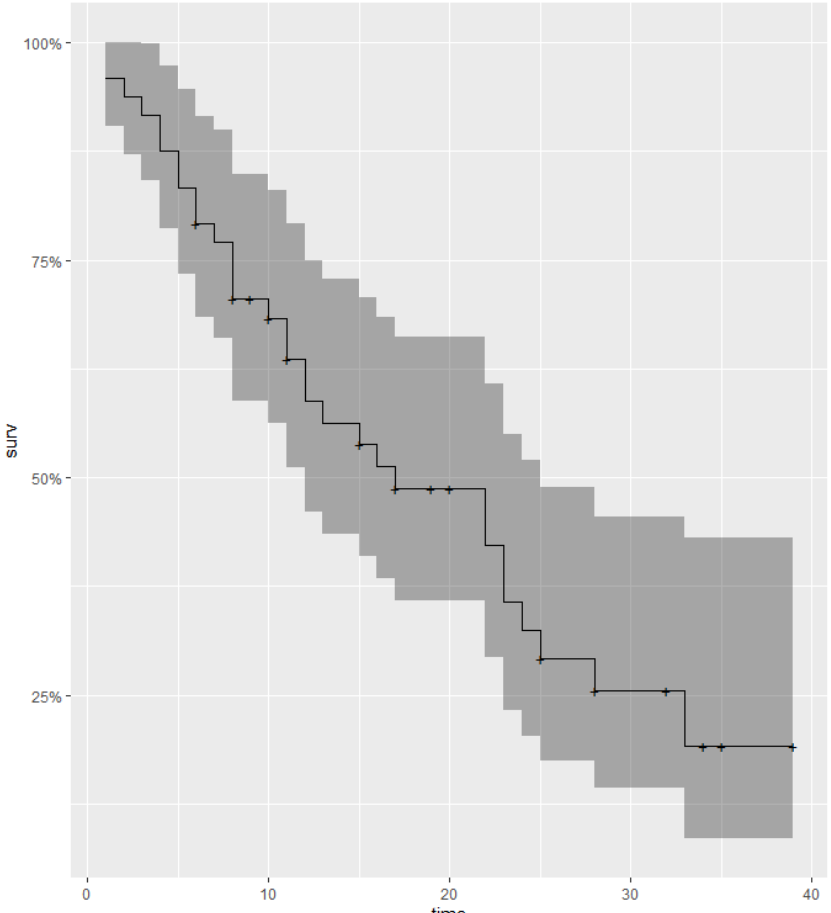

Figur: Kaplan-Meier for to grupper

```
> km <- survfit(Surv(studytime, died) ~ factor(drug), data=drugtr)
> km
Call: survfit(formula = Surv(studytime, died) ~ factor(drug), data = drugtr)

                n events median 0.95LCL 0.95UCL
factor(drug)=0 20     19      8       5      15
factor(drug)=1 28     12     28      23      NA
> autoplot(km)
```

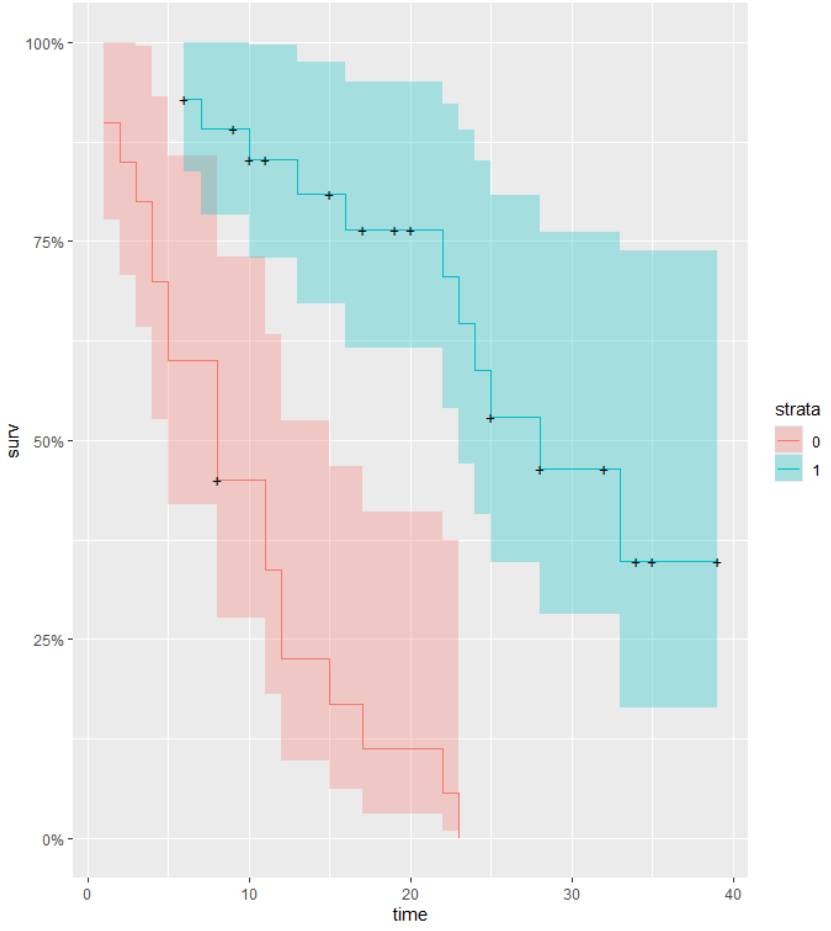

Logrank-test

- Vi kan sammenligne to (eller flere) Kaplan-Meier-kurver med en logrank-test
- Nulhypotesen er at de to kurver er ens
- Testen fortæller os dog ikke, hvor stor forskellen er, hvis den er signifikant
- Så derfor er Cox-regression ofte en bedre løsning

```
> survdiff(Surv(studytime, died) ~ factor(drug), data=drugtr)
Call:
survdiff(formula = Surv(studytime, died) ~ factor(drug), data = drugtr)

                N Observed Expected (O-E)^2/E (O-E)^2/V
factor(drug)=0 20       19     7.25     19.07      28.3
factor(drug)=1 28       12    23.75      5.82      28.3

 Chisq= 28.3  on 1 degrees of freedom, p= 1e-07
```

Eksempel (Vinther et al. 2016)

The Kaplan–Meier survival estimator was used to model the risk of recurrent ischemic strokes/TIAs or death in the 2 groups, and the log-rank test was used to test whether there were any differences between the groups. A Cox proportional hazards model was used to estimate the hazard ratios of runs of PACs in relation to the primary combined endpoint and to the endpoint of death in crude and adjusted models.

Eksempel (Vinther et al. 2016)

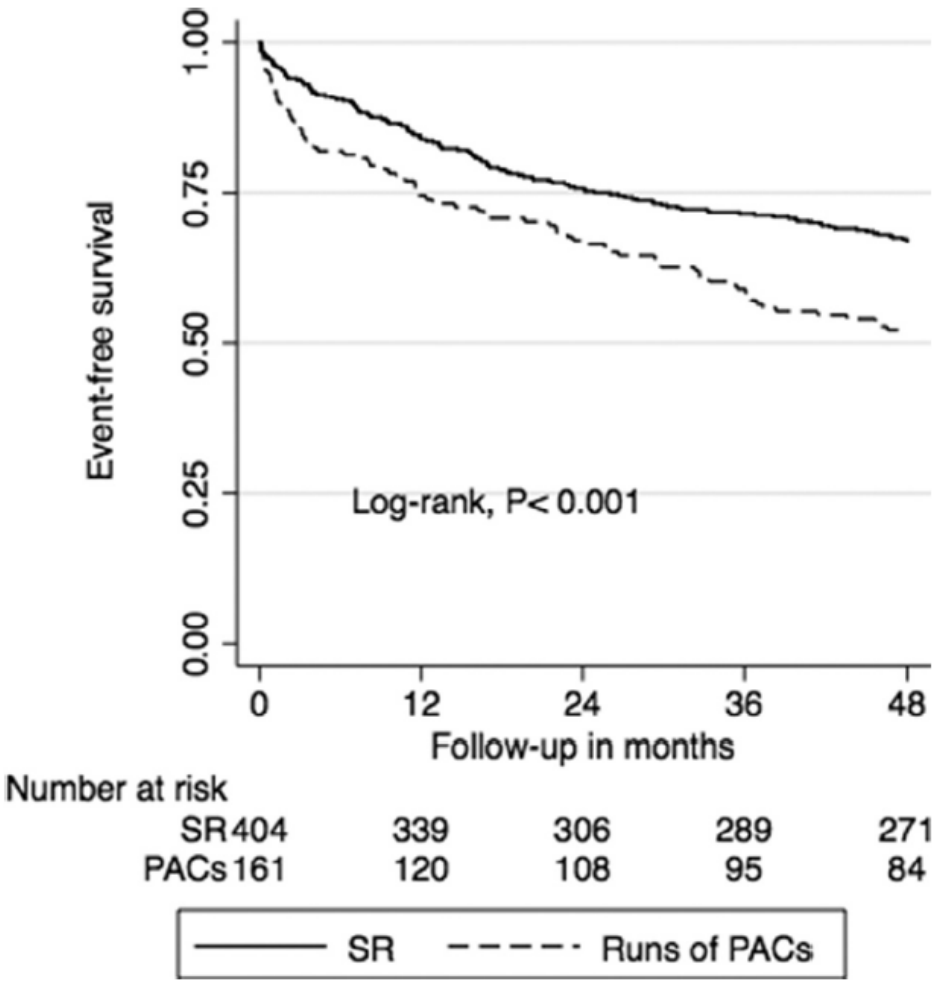

Figure 1. *Kaplan–Meier survival estimate of recurrent ischemic strokes/ TIAs or death-free survival in patients, with and without runs of PACs. SR indicates patients without runs of PACs. Abbreviations: PAC, premature atrial complex; TIA, transient ischemic attack.*

Sammenfatning: Kaplan-Meier og log-rank-test

- Overlevelsesdata skal analyseres med specielle metoder
- Hvis dette ignoreres, udløses der bias på grund af censurering
- Kaplan-Meier metoden kan beskrive risiko over tid for en eller flere grupper
- Typisk rapporteres denne som Kaplan-Meier-kurve
- Forskel mellem kurver kan testes med log-rank-test (men Cox-regression er ofte bedre)

Cox-regression

- Cox-regressionen kombinerer
  - en regression (der minder om logistisk/Possion-regression)
  - med en ikke-parametrisk overlevelseskurve (grundlæggende en Kaplan-Meier-kurve)

$$\lambda(t|X_i) = \lambda_0(t)\exp(\beta_1 X_{i1} + \cdots + \beta_p X_{ip})$$

- $HR_k = \exp(\beta_k)$ er hazard-ratioen
- Fortolkes som relativ risiko for udfaldet mellem to grupper indenfor meget krt tid
- Eksempel: Risikoen for at dø med den ny behandling i morgen er 20% højere end med den gamle behandling (HR=1.2)

R: Cox-regression

```
> cox <- coxph(Surv(studytime, died) ~ factor(drug), data = drugtr)
> summary(cox)
Call:
coxph(formula = Surv(studytime, died) ~ factor(drug), data = drugtr)
  n= 48, number of events= 31
                 coef exp(coef) se(coef)      z Pr(>|z|)
factor(drug)1 -2.0850    0.1243   0.4443 -4.692  2.7e-06 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

              exp(coef) exp(-coef) lower .95 upper .95
factor(drug)1    0.1243      8.045   0.05203     0.297
Concordance= 0.727  (se = 0.035 )
Likelihood ratio test= 25.05  on 1 df,   p=6e-07
Wald test            = 22.02  on 1 df,   p=3e-06
Score (logrank) test = 29.15  on 1 df,   p=7e-08
> exp(coef(cox))
factor(drug)1
     0.124307
> exp(confint(cox))
                   2.5 %    97.5 %
factor(drug)1 0.05203266 0.2969717
```

Proportional-hazard-antagelsen

- Cox-regressionen antager at HR er den samme på alle tidspunkter i follow-up-tiden
- Dette kaldes *proportional-hazard-antagelsen*
- Tænk på det som at de kurver på en Kaplan-Meier-kurve følges ad paralelt
- For Cox-regression plejer vi at tjekke det med en test

```
> cox.zph(cox, transform="km")
               chisq df    p
factor(drug) 0.00144  1 0.97
GLOBAL       0.00144  1 0.97
```

R: Cox-regression med justering

```
> cox <- coxph(Surv(studytime, died) ~ factor(drug)+age, data = drugtr)
> summary(cox)
Call:
coxph(formula = Surv(studytime, died) ~ factor(drug) + age, data = drugtr)
  n= 48, number of events= 31
                  coef exp(coef) se(coef)      z Pr(>|z|)
factor(drug)1 -2.33853   0.09647  0.46052 -5.078 3.81e-07 ***
age            0.11650   1.12355  0.03745  3.111  0.00186 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
              exp(coef) exp(-coef) lower .95 upper .95
factor(drug)1   0.09647      10.37   0.03912    0.2379
age             1.12355       0.89   1.04405    1.2091
Concordance= 0.809  (se = 0.041 )
Likelihood ratio test= 34.8  on 2 df,   p=3e-08
Wald test            = 29.66  on 2 df,   p=4e-07
Score (logrank) test = 37.42  on 2 df,   p=7e-09
> exp(coef(cox))
factor(drug)1           age
   0.09646891    1.12355374
> exp(confint(cox))
                   2.5 %    97.5 %
factor(drug)1 0.03911946 0.2378931
age           1.04404651 1.2091157
```

Proportional-hazard-antagelsen med justering

- Hvis vi har flere forklarende variable får vi
  - En p-værdi for proportionalitet for hver af dem
  - Og en overordnet (GLOBAL) p-værdi
  - De skal gerne alle være ikke-signifikant
- Hvis de er (meget) signifikant, kan der
  - Justeres for ekstra variable
  - Tilføjes interaktioner
  - Inkluderes tidsvarierende HR (ikke i dette kursus)

```
> cox.zph(cox, transform="km")
               chisq df    p
factor(drug) 0.0209  1 0.88
age          0.6725  1 0.41
GLOBAL       0.6726  2 0.71
```

Eksempel (Vinther et al. 2016)

Table 2. *Cox regression models showing the risk of recurrent ischemic strokes/TIAs or death and death in relation to runs of PACs and other risk factors*

	Recurrent ischemic stroke/TIA or death		Death	
	HR (95% CI)	*P*	HR (95% CI)	*P*
Crude model				
Runs of PACs	1.63 (1.23-2.15)	.001	1.79 (1.30-2.47)	<.001
Adjusted model*				
Runs of PACs	1.32 (.98-1.78)	.068	1.39 (.99-1.96)	.059
Age	1.04 (1.03-1.06)	<.001	1.07 (1.06-1.09)	<.001
Male sex	1.27 (.95-1.07)	.111	—	—
Previous stroke	1.45 (1.04-2.02)	.028	1.32 (.88-1.96)	.177
Adjusted model†				
Runs of PACs	1.47 (1.06-2.04)	.023	1.54 (1.05-2.23)	.028
Age	1.04 (1.03-2.04)	<.001	1.08 (1.06-1.11)	<.001
Male sex	1.41 (1.02-1.96)	.037	1.65 (1.12-2.43)	.011
Previous stroke	1.51 (1.05-2.17)	.026	1.31 (.85-2.03)	.225

Udvidelser til Cox-regression

- Hvis der er konkurrerende hændelser, der kan fjerne personer fra risikogruppen
  - HR kan fortolkes som audfald-specific (*cause specific*) HR
  - Virker fint hvis det konkurrerende udfald er rimelig sjældent sammenlignet med udfaldet af interesse
  - Ellers findes der specialiserede metoder (ikke i dette kursus)
- Hvis vi ønsker at forudsige på nye personer
  - Cox kan gøre det, men kan være bøvlet, hvis vi ikke har data på mange tidspunkter
  - Parametriske overlevelsesmodeller kan gøre det med færre problemer (ikke i dette kursus)

Sammenfatning: Cox-regression

- Cox-regression bruges til at analysere overlevelsesdata
  - med flere forklarende variable (f.eks. konfundere)
  - med numeriske forklarende variable
  - for at få effektestimater (HR)
- Husk at tjekke proportional-hazard-antagelsen
  - og gøre noget ved det, hvis ikke den er opfyldt
- HR rapporteres med konfidensintervaller (og måske p-værdi)
- HR skal fortolkes lidt forsigtigt
  - Forskel i risiko/incidence indenfor (meget) kort tidshorisont

Overblik over metoder

Exposure→Outcome/response

Exposure(x)	Response(y)				
	binary	r categories	counts	continuous	survival time
binary (yes/no)	2 × 2 table χ^2-test Odds-ratio/rel. risk	r × 2 table χ^2_{r-1}-test Odds-ratio/rel. risk	2 rates diff in rates	comparison of 2 means *t*-test, Wilcoxon diff in means	Kaplan-Meier curves log-rank test Hazard ratio
c groups	2 × c table χ^2_{c-1}-test Odds-ratio/rel. risk	r × c table $\chi^2_{(r-1)\times(c-1)}$-test Odds-ratio/rel. risk	poisson Incidence rate ratio	comparison of c means multiple regression means	Cox-regression Hazard ratio
continuous and adjustment for covariates	logistic regression	ordinal regression proportional odds multinomial regression	poisson regression negative binomial regression	regression multiple lin regression	Cox-regression competing risk regression

- For grouped observations, eg. repeated measurements, models with random effects extends above models: Generalized linear mixed models

Spørgsmål?