Introduktion til kurset og R

Sören Möller

Institut for Sundhedstjenesteforskning
Syddansk Universitet

3. februar 2026

Formål

Formålet med faget er at give de studerende indsigt i biostatistiske og epidemiologiske forskningsmetoder, herunder forståelse for disse metoders styrker og svagheder, samt styrke deres evne til kritisk at vurdere publiceret litteratur. Desuden at give de studerende færdigheder til selv at analysere kvantitative data i sundhedsvidenskabelige studier.

Forudsætninger

- Det forventes, at den studerende har et vist kendskab til engelsk og gerne har erfaring med læsning af videnskabelige artikler på engelsk.
- Desuden forventes der at den studerende har kendskab til stoffet svarende til faget: K5-K6: Evidensbaseret medicin.
- I praksis, vil i også opleve noget repetition fra B4 og B10.

Målbeskrivelse

- Redegøre for
  - epidemiologiske undersøgelsesdesign
  - basale epidemiologiske og diagnostiske mål og begreber
  - anvendelse af statistiske metoder til analyse af kategoriske og kontinuerte udfald
  - sammenhængen mellem epidemiologiske og statistiske metoder
- Vælge, bestemme, forklare og vurdere deskriptive mål og associations-mål
- Diskutere bias i epidemiologiske undersøgelser
- Vurdere anvendeligheden af diagnostiske tests og kliniske effektmål
- Anvende statistiske modeller på data ved brug af statistisk software
- Kritisk læse og vurdere epidemiologisk originallitteratur
- Demonstrere overblik over den grundlæggende struktur i et forskningsprojekt

Undervisere

- Forelæsninger:
  - Statistik: Sören Möller, Institut for Sundhedstjenesteforskning (Epidemiologi, Biostatistik & Biodemografi)
  - Epidemiologi: Mette Bliddal, Klinisk Institut (Gynækologi og obstetrik)
  - Epidemiologi: Jens-Jakob Kjær Møller, Klinisk Institut (OPEN)
- Øvelser:
  - Ida Asta Olsen, Statens Institutr for Folkesundhed (Epidemiologi og Interventioner)
  - Helle Bruhn, Institut for Sundhedstjenesteforskning (Epidemiologi, Biostatistik & Biodemografi)
  - Katrine Mose Hansen, Institut for Sundhedstjenesteforskning (Klinisk farmakologi, farmaci og Miljømedicin)

Materialer brugt i kurset

- Jesper Krog, Carsten Hjortshøj, Morten Arendt Rasmussen og Simon Francis Thomsen: ”Biostatistik epidemiologi” (1. udg), FADLs forlag 2022
- Svend Juul, Bodil Hammer Bech, Christina Catherine Dahm og Dorte Rytter: "Epidemiologi og evidens" (4. udg), munksgaard 2025
- Hadley Wickham, Mine Çetinkaya-Rundel, og Garrett Grolemund: "R for Data Science" (2. udg), frit tilgængeligt på https://r4ds.hadley.nz/
- Videnskabelige artikler, som lægges ud til jer i løbet af kurset.
  - I dag: Overholser & Sowinski, "Biostatistics Primer: Part I & II", Nutrition in Clinical Practice, 2007

Eksamen

- Individuel skriftlig hjemmeopgave af 4 timers varighed, der skrives på dansk
- Materialet til eksamen, f.eks. udleveret artikel, kan være på engelsk.
- Der vil 3 dage før eksamen blive udleveret materiale.
  - Videnskabelig artikel
  - (Syntetisk) datasæt
- Udlevering af materiale tirsdag den 23. marts kl. 9.00 i Digital Eksamen.
- De 4 timers hjemmeopgave ligger fredag den 26. marts kl. 09.00-13.00.

R

- Vi vil bruge den statistiske software R
- Den er open source og frit tilgængeligt
- Den kan downloades og installeres fra https://www.r-project.org/
- Vi anbefaler i opså installerer brugergrænsefladen RStudio fra https://posit.co/download/rstudio-desktop/

Datasæt og histogram

Løbetider for mænd og kvinder for Gendarmsstienløbet 2015 og 2016 (simuleret datasæt inspireret af originalen).

```
> load(file="runningtimes.RData")
> hist(subset(runningtimes,Sex==0)$time2015)
```

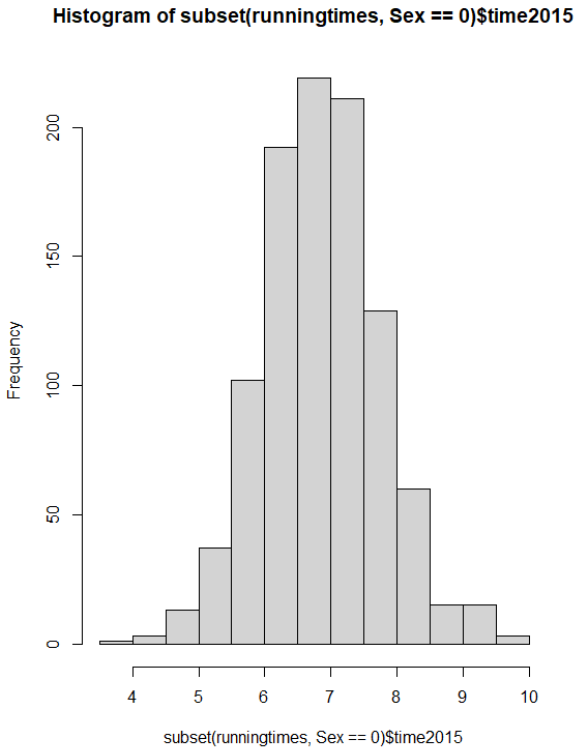

Middelværdi

Middelværdien $\bar{x}$ er et mål for den gennemsnitlige størrelse af værdierne i datasættet.

$$\sum x = \text{ summen af alle målingerne}$$

$$n = \text{ antal målinger}$$

$$\bar{x} = \frac{\sum x}{n} = \text{ middelværdi af målingerne}$$

$\sum x_i$ betyder summen af alle x_i

Median

Medianen $x_{0,5}$ er et mål for den størrelsesmæssig midterste måling

- Målingerne sorteres efter størrelse
- Hvis der er et ulige antal målinger, vælges den midterste x og

$$x_{0,5} = x$$

- Hvis der er et lige antal målinger, vælges de to midterste x_L og x_R og

$$x_{0,5} = \frac{x_L + x_R}{2}$$

Eksempel: Middelværdi og median

Vi vil beregne middelværdien og medianen af løbetiden for mændende i 2015.

```
> mean(subset(runningtimes,Sex==0)$time2015)
[1] 6.857519
> median(subset(runningtimes,Sex==0)$time2015)
[1] 6.860118
```

Middelværdi versus median

- Middelværdien undersøges i de fleste statistiske modeller og reporteres typisk i artikler
- Middelværdien har en klar fortolkning som gennemsnitlig måling
- Middelværdien er meget følsomt over for ekstreme målinger
- Medianen er mindre følsomt over for ekstreme målinger
- Medianen er sværere at fortolke
- Hvis fordelingen er symmetrisk vil median og middelværdi ligge tæt på hinanden

Normalfordelingen

Normalfordelingen er den mest brugte fordeling i statistik med numeriske målinger.

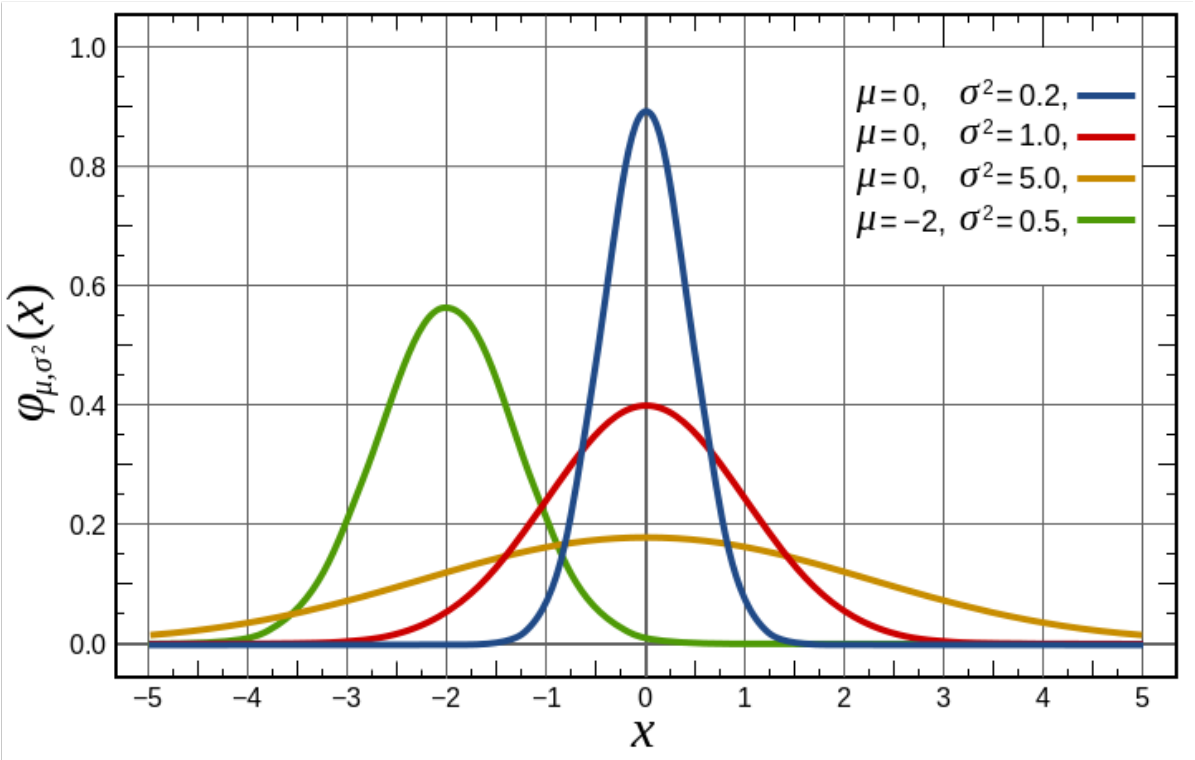

"Gauss 1" by Izabela 09k - Own work. CC-BY-SA 3.0 via Wikimedia Commons

Histogram med normalfordeling

En måde at tjekke på om data er normalfordelt er at tegne en normalfordeling med på hisogrammet. Det kan dog være ret svært at vurdere hvor god det passer sammen.

```
> hist(subset(runningtimes,Sex==0)$time2015, freq = FALSE)
> curve(dnorm(x,mean(subset(runningtimes,Sex==0)$time2015),
sd(subset(runningtimes,Sex==0)$time2015)),
col = 2, lty = 2, lwd = 2, add = TRUE)
```

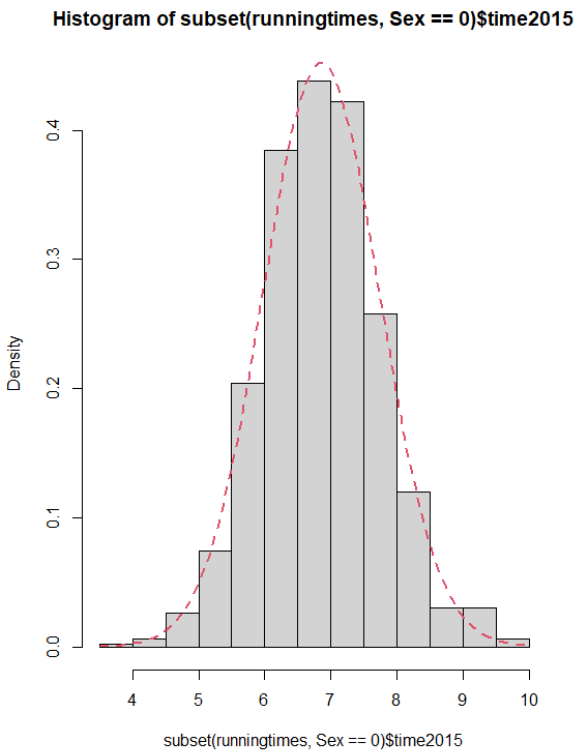

Kvantilplot for normalfordeling

Den typiske måde at tjekke for normalfordeling er et kvantilplot, hvor ønsket er at prikkerne ligger på linjen.

```
> qqnorm(subset(runningtimes,Sex==0)$time2015)
> qqline(subset(runningtimes,Sex==0)$time2015
```

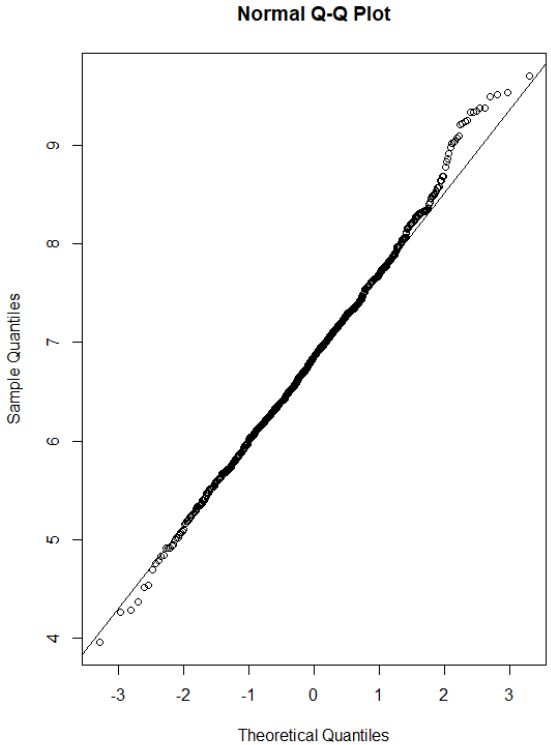

Varians

Variansen s^2 og spredningen s er mål for hvor meget variation, der er i vores datasæt

$$s^2 = \frac{\sum(x-\bar{x})^2}{n-1} = \frac{(\sum x^2) - n\bar{x}^2}{n-1}$$
$$s = \sqrt{s^2}$$

hvor

$$\sum x^2 = \text{ summen af målingernes kvadrater.}$$

Husk $\sum x^2 \neq (\sum x)^2$!

Fraktiler (quantiles)

- Fraktiler er bestemte positioner i de ordnede data
- For $0 < p < 1$ er p-fraktilen et tal, der ligger sådan at
  - højst $p \cdot n$ af målingerne er mindre end (eller lig med) dette tal
  - højst $(1 - p) \cdot n$ af målingerne er større end (eller lig med) dette tal
- Mange lettere forskellige formler.
- I skal ikke kunne beregne dem i hånden, men skal forstå hvad de betyder
- *Medianen* er $0,5$-fraktilen
- 1. og tredje *kvartil* er 0,25 og 0,75 fraktilen
- *Percentiler* er fraktiler med hele hundrededele
  - 0.37-fraktilen kaldes 37%-percentilen

Eksempel: Variationsmål

Vi vil beregne varians, spredning og fraktiler af løbetiden for mændende i 2015.

```
> var(subset(runningtimes,Sex==0)$time2015)
[1] 0.7796559
> sd(subset(runningtimes,Sex==0)$time2015)
[1] 0.8829813
> quantile(subset(runningtimes,Sex==0)$time2015,  probs = c(0.25, 0.75))
     25%      75%
6.261056 7.397889
```

Spredning versus fraktiler

- Spredningen er meget følsom over for ekstreme målinger
- Spredningen er let og entydigt at beregne
- Spredningen er "symmetrisk" omkring middelværdien
- Fraktilerne er mindre følsomme over for ekstreme målinger
- Fraktilerne er besværlige og ikke entydige at beregne
- Fraktilerne kan ligge forskelligt langt fra medianen på begge sider
- Vi kan ikke uden videre sammenligne fraktiler med spredningen

Konfidensintervaller

- Vi får et *estimat* $\bar{x}$ for middelværdien fra vores data.
- Vi ønsker at vide hvor sikkert vi kan være på estimatet
- Idé:
  - Bestem hvor sikkert vi vil være (typisk 95%)
  - Beregn et interval omkring estimatet som den ægte middelværdi ligger i med 95% sikkerhed
- Kræver visse antagelser for fordelingen
  - Typisk antages at numeriske data er normalfordelt
- Vi ønsker også at beregne konfidensintervaller for forskellen mellem middelværdien i to uafhængige populationer

Fortolkning af konfidensinterval

Foretager vi 100 studier på tilsvarende datasæt fra den samme population forventer vi at (cirka) 95 af dem indeholder den sande middelværdi.

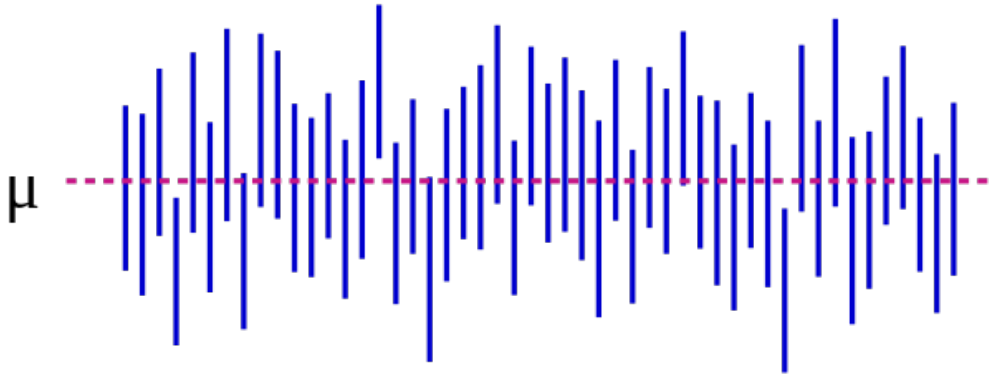

Vi siger at den sande middelværdi med **95% sikkerhed** ligger i konfidensintervallet og kalder det også for **sikkerhedsinterval**.

"Picturing 50 realisations of a 95%-confidence interval" by Tsyplakov - Own work. public domain via Wikimedia Commons

Eksempel: Konfidensinterval

```
> t.test(subset(runningtimes,Sex==0)$time2015)

        One Sample t-test

data:  subset(runningtimes, Sex == 0)$time2015
t = 245.59, df = 999, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 6.802726 6.912312
sample estimates:
mean of x
 6.857519
```

Hypotesetest

Ofte vil vi sammenligne vores estimat med en forud kendt værdi for at finde ud af, om der er en (signifikant) forskel.

H_0 :	observation	$=$	foventede		Nul-hypotese
H_a :	observation	$\neq$	foventede		Alternativ hypotese (tosidet)

Vi ønsker at finde ud af, om nulhypotesen er så usandsynligt, givet vores data, at vi kan forkaste den.

Eksempel

Kunne middelværdien for mænds løbetider i virkeligheden være 7 *og ikke de* $6,86$ *vi observerer?*

Etsidet: Vi kan også undersøge H_a med $<$ eller $>$ i stedet for $\neq$, men det gør vi ikke her.

Signifikansniveau og p-værdi

p-værdien er sandsynligheden for at få vores *estimat* eller noget der er længere væk fra det forventede, under antagelse af nulhypotesen er rigtigt.

Eksempel

p-værdi: Sandsynligheden for at observere en middelværdi på $6,86$ *eller længere væk fra* 7*, hvis den i virkeligheden er* 7*.*

Signifikansniveauet α er, hvor lav en p-værdi vi vil acceptere inden vi forkaster nulhypotesen.

- Højt signifikansniveau giver lav sikkerhed, men har brug for få data (f.eks. $\alpha = 0,10$)
- Lavt signifikansniveau giver høj sikkerhed, men har brug for mange data (f.eks. $\alpha = 0,01$)
- For det meste bruger vi $\alpha = 0,05$

Eksempel: Hypotesetest for én middelværdi fra en normalfordeling

```
> t.test(subset(runningtimes,Sex==0)$time2015,mu=7)

        One Sample t-test

data:  subset(runningtimes, Sex == 0)$time2015
t = -5.1028, df = 999, p-value = 4.005e-07
alternative hypothesis: true mean is not equal to 7
95 percent confidence interval:
 6.802726 6.912312
sample estimates:
mean of x
 6.857519
```

Antager at observationerne er normalfordelt.

Eksempel: Hypotesetest for forskel mellem to middelværdier

```
> t.test(runningtimes$time2015~runningtimes$Sex)

        Welch Two Sample t-test

data:  runningtimes$time2015 by runningtimes$Sex
t = -18.107, df = 1995.5, p-value < 2.2e-16
alternative hypothesis: true difference in means between group 0 and group 1 is not equal to 0
95 percent confidence interval:
 -0.7786639 -0.6264727
sample estimates:
mean in group 0 mean in group 1
       6.857519        7.560087
```

Antager at observationerne i begge grupper er normalfordelt.

Hvad hvis data ikke er normalfordelt?

- Hvis data ikke er normalfordelt, er t-test misvisende.
- Der er tre typiske løsninger:
  - Transformer data (tag f.eks. logaritmen) og brug t-test
    - Tjek at resultatet er normalfordelt!
  - Wilcoxon ranksum-test
    - Tester om gruppernes **fordelinger** er forskubbet mod hinanden
  - Median-test
    - Tester om **medianen** er forskellig
- ranksum-test og median-test har mindre styrke end t-test
- Bemærk at disse to tester forskellige ting!

Eksempel: Hypotesetest for forskel mellem to middelværdier

```
> wilcox.test(runningtimes$time2015~runningtimes$Sex)

        Wilcoxon rank sum test with continuity correction

data:  runningtimes$time2015 by runningtimes$Sex
W = 280155, p-value < 2.2e-16
alternative hypothesis: true location shift is not equal to 0

> install.packages("agricolae")
> library(agricolae)
> Median.test(runningtimes$time2015,runningtimes$Sex)

The Median Test for runningtimes$time2015 ~ runningtimes$Sex

Chi Square = 204.8   DF = 1   P.Value 1.872513e-46
Median = 7.201405

    Median    r      Min      Max      Q25      Q75
0 6.860118 1000 3.965887  9.69783 6.261056 7.397889
1 7.535074 1000 4.966655 10.86067 6.971146 8.124214

Post Hoc Analysis

Groups according to probability of treatment differences and alpha level.

Treatments with the same letter are not significantly different.

  runningtimes$time2015 groups
1              7.535074      a
0              6.860118      b
```

Kategoriske variable

En kategorisk variable, er noget der kun kan tage nogle bestemte udfald/værdier.

- Kan tænkes på som gruppeinddeling
- Kan have to eller flere mulige værdier
- Kan være ordnet (ordinal)
  - Uvigtigt ved to mulige værdier
  - Vi kommer ikke mere ind på ordinale variable i dag
- Eksempler:
  - Køn (mand/kvinde)
  - Død/levende
  - Behandling (konventionel/ny eller behandling/placebo)
  - Geografisk (landsdel/region/kommune)
  - Strukturel (behandler/sygehusafdeling)
  - Socialklasse

Proportioner

Proportionen for værdien i betegner den andel af vores målinger der har denne værdi.

$$p_i = \frac{d_i}{n}$$

hvor n er antal observationer i alt og d_i er antal observationer der har værdien i.

- Proportioner angives ofte i procent
- Hvis der kun er to udfald, angiver vi ofte kun det ene af de to proportioner

Eksempel: Proportion af kaffedrikkere

```
> load(file="coffee.RData")
> install.packages("gmodels")
> library(gmodels)
> CrossTable(coffee$coffee,coffee$treatment,
prop.c=T,prop.r=F,prop.t=F,prop.chisq = F)
   Cell Contents
|-------------------------|
|                       N |
|           N / Col Total |
|-------------------------|
Total Observations in Table:  178
              | coffee$treatment
coffee$coffee |         0 |         1 | Row Total |
--------------|-----------|-----------|-----------|
            0 |        57 |        64 |       121 |
              |     0.576 |     0.810 |           |
--------------|-----------|-----------|-----------|
            1 |        42 |        15 |        57 |
              |     0.424 |     0.190 |           |
--------------|-----------|-----------|-----------|
 Column Total |        99 |        79 |       178 |
              |     0.556 |     0.444 |           |
--------------|-----------|-----------|-----------|
```

Eksempel: Konfidensinterval for proportion

Der er forskellige metoder for at bestemme konfidensintervaller for proportioner. Vi vil her bruge det eksakte (Clopper-Pearson) konfidensinterval, men forskellen er normalt ret lille.

```
> install.packages("PropCIs")
> library(PropCIs)
> exactci(length(subset(coffee,coffee==1)$coffee),
length(coffee$coffee),conf.level=0.95)
data:

95 percent confidence interval:
 0.2524008 0.3941547
```

χ^2-fordelingen

χ^2-fordelingen ("Chi-kvadrat fordelingen") beskriver fordelingen af en sum af uafhængige normalfordelinger, der er sat i anden, den bruges til at beskrive forskellen mellem observerede og forventede antal i 2x2-tabellerne.
χ^2-fordelingen har et antal frihedsgrader, som altid er 1, når vi kigger på 2x2-tabeller.

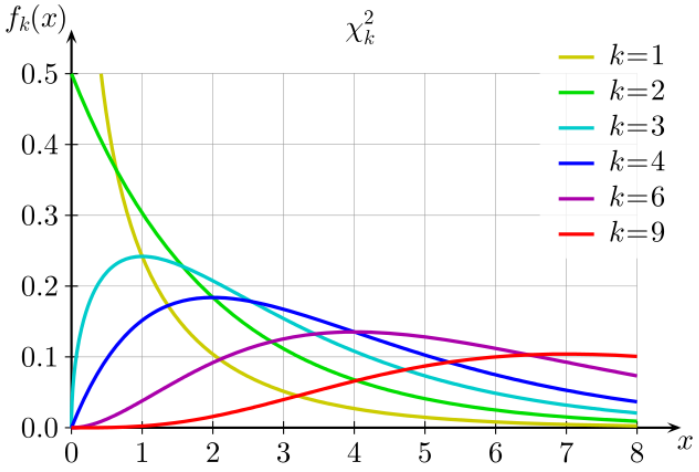

"Chi-square pdf" by Geek3 - Own work. CC-BY 3.0 via Wikimedia Commons

χ^2 test

For at teste om der er forskel mellem proportionen i de to grupper ($H_0 : p_1 = p_2, H_a : p_1 \neq p_2$) bestemmer vi

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

hvor vi summer over alle fire celler i tabellen og O er antal observerede og E antal forventede i cellen.
Resultatet er χ^2-fordelt med 1 frihedsgrad, og vi afviser H_0 hvis χ^2 er større end 3,84 på 5% signifikansniveau.
Dette kræver at alle tal i tabellen er mindst 5, hvis dette ikke er opfyldt kan vi bruge Fishers eksakte test i stedet for.

Eksempel: χ^2-test og Fishers eksakte test

Der er forskellige metoder for at bestemme konfidensintervaller for proportioner. Vi vil her bruge det eksakte (Clopper-Pearson) konfidensinterval, men forskellen er normalt ret lille.

```
> chisq.test(coffee$coffee,coffee$treatment)

        Pearson's Chi-squared test with Yates' continuity correction

data:  coffee$coffee and coffee$treatment
X-squared = 10.037, df = 1, p-value = 0.001535

> fisher.test(coffee$coffee,coffee$treatment)

        Fisher's Exact Test for Count Data

data:  coffee$coffee and coffee$treatment
p-value = 0.001137
alternative hypothesis: true odds ratio is not equal to 1
95 percent confidence interval:
 0.1483342 0.6628498
sample estimates:
odds ratio
 0.3201377
```

Spørgsmål?